本科毕业设计（论文）

基于脑电的抑郁症诊断方法研究

学　　院	自动化科学与工程学院
专　　业	智能科学与技术
学生姓名	徐筠懿
学生学号	202130461854
指导教师	顾正晖
提交日期	2025 年 6 月 2 日

华南理工大学

学位论文原创性声明

本人郑重声明：所呈交的论文是本人在导师的指导下独立进行研究所取得的研究成果。除了文中特别加以标注引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写的成果作品。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律后果由本人承担。

作者签名：徐筠懿　　日期：2025 年 6 月 2 日

学位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，即：学校有权保存并向国家有关部门或机构送交论文的复印件和电子版，允许学位论文被查阅；学校可以公布学位论文的全部或部分内容，可以允许采用影印、缩印或其它复制手段保存、汇编学位论文。本人电子文档的内容和纸质论文的内容相一致。

作者签名：徐筠懿　　日期：2025年6月2日

指导教师签名：　　日期：2025年6月2日

作者联系电话：13922885092　　电子邮箱：2488874820@qq.com

摘　要

重度抑郁症（Major Depressive Disorder，MDD）已然成为了一个全球范围的健康问题，也是精神问题致残的主要原因。由于 MDD 患者间的个体差异性，医生在诊断时，抑郁自评量表（Self-rating depression scale，SDS）结果的参考价值十分有限，特别是在 SDS 在患者具有严重迟缓症状，文化水平较低或智力水平较差的情况下。因此，本研究采用更客观的脑电图（Electroencephalogram，EEG）对 MDD 患者与健康人群对照组（Healthy Controls，HC）进行分类，同时对 MDD 患者群体内部进行聚类分析，研究 MDD 亚型（Subtype）以及亚型具有的 EEG 通道特征。本文的主要研究内容如下：

（1）本研究基于 M-ShallowConvNet，针对 MDD 群体与 HC 群体在多频段（Delta、Theta、Alpha、Beta、Low Gamma、High Gamma）脑电信号下的分类性能展开对比分析。M-ShallowConvNet 改进了 ShallowConvNet 的核心结构，在相同数据集上的分类任务性能有显著提升。利用该模型，本研究发现在六个不同频段情况下对两个群体进行分类的结果中，High Gamma 频段的效果最好。该结果表明医疗人员在诊断 MDD 的过程中可以将重点放在该频段，以健康人群为基准对就诊人员进行评估。

（2）本研究还对 MDD 群体的 High Gamma 频段进行进一步分析，采用手肘法和轮廓系数法双重验证确定最佳聚类个数，随后对 MDD 群体进行聚类可视化以及绘制不同群体的脑区热力图，分析各个脑区通道的信号差异。这对研究不同亚型、MDD 异质性，以及从哪些脑区入手对 MDD 患者进行治疗都具有一定帮助。同时，本研究也对各亚型之间进行功能连接性（Functional Connectivity）分析，更直观地体现脑区差异性。结果表明，Subtype 1 偏向“后部—视觉/空间”网络的高度同步，Subtype 2 偏向“前额—颞叶”网络的显著耦合，两者在脑区网络分布与功能侧重点上存在明显差异。

关键词： 重度抑郁症；脑电图；M-ShallowConvNet 模型；功能连接性

Abstract

Major Depressive Disorder (MDD) has emerged as a global health concern and a leading cause of disability attributed to psychiatric conditions. Due to the substantial individual heterogeneity among MDD patients, the diagnostic reference value of Self-Rating Depression Scale (SDS) results is significantly limited in clinical practice, particularly for patients with severe psychomotor retardation, limited education, or cognitive impairment. To address this challenge, this study employs Electroencephalogram (EEG) signals—a more objective neurophysiological biomarker—to differentiate MDD patients from Healthy Controls (HC), while conducting cluster analysis within the MDD population to investigate potential subtypes and their distinctive EEG channel characteristics. The main contributions of this research are outlined as follows:

(1) This study compares ShallowConvNet and its enhanced M-ShallowConvNet for MDD/HC classification across six EEG bands (Delta、Theta、Alpha、Beta、Low Gamma、High Gamma). Incorporating multi-scale convolutional kernels and attention mechanisms, M-ShallowConvNet achieves significant accuracy improvement, with High Gamma showing optimal performance. This discovery provides clinicians with a neurophysiological reference benchmark, recommending prioritized analysis of High Gamma oscillations during MDD assessments by contrasting patient data against established HC norms.

(2) The study further investigated the MDD cohort in the High Gamma band by using both the elbow method and silhouette coefficient to determine the optimal number of clusters. Then, I visualized clusters and generated subgroup heatmaps to reveal inter-regional signals, clarifying MDD heterogeneity and guiding targeted interventions. This study also performed functional connectivity analyses between MDD subtypes to clearly highlight regional network differences. Subtype 1 shows high synchronization in posterior visual-spatial networks, while Subtype 2 shows strong coupling in fronto-temporal networks.

Keywords: Major Depressive Disorder; Electroencephalogram; M-ShallowConvNet Model; Functional Connectivity

目　录

摘　要 I

Abstract II

目　录 III

第一章 绪论 1

1.1 研究背景及意义 1

1.2 研究现状 2

1.3 论文结构 3

第二章 研究基础和方法概述 4

2.1 脑电神经生理学基础 4

2.2 脑电与抑郁症的关系 4

2.2.1 脑电频段与抑郁症的关联 4

2.2.2 基于脑电的抑郁症辅助诊断方法 5

2.3 模型选择与聚类方法 7

2.3.1 模型选择依据 7

2.3.2 聚类方法介绍 9

2.3.2.1 手肘法 9

2.3.2.2 轮廓系数法 9

2.3.2.3 K-means 聚类 10

2.4 TDBRAIN 数据集 11

2.4.1 数据集介绍 11

2.4.2 数据预处理 12

第三章 基于 M-ShallowConvNet 的 MDD 诊断 13

3.1 模型介绍 13

3.2 实验设计 17

3.2.1 数据集分析 17

3.2.2 训练方法 17
3.3 实验流程 20
3.4 实验结果 23
第四章 MDD 群体的亚型分析 28
4.1 实验设计 28
4.2 实验流程 28
4.3 实验结果 30
总结与展望 36
1. 论文工作总结 36
2. 工作展望 37
参考文献 38
致谢 42

第一章 绪论

1.1 研究背景及意义

重度抑郁症（Major Depressive Disorder，MDD）是一个常见的主要的健康问题，也是全球致残的主要原因。 MDD 的行为症状包括：时常感到悲伤和无助，失去快乐或无法体会快乐，缺乏动力以及认知缺陷[1]。传统的精神障碍研究模式将 MDD 患者与正常人群进行比较，却忽略了 MDD 患者间的个体差异性，这对 MDD 的研究并没有很大帮助，更无法研究由这种异质性而产生的 MDD 亚型（Subtype），去研究它们的机理了[2]。也正是 MDD 本身的高度个体特异性，导致传统的治疗方法：抗抑郁药物和认知行为治疗，带来的治疗效果并不理想，有效率只有 40-50%左右，缓解率更是仅 30-40%左右[3]。因此，人们开始对 MDD 的机理进行研究，期望能够在了解 MDD 的发病原理后对 MDD 患者展开个性化和针对性的治疗。

脑电图（Electroencephalogram，EEG）是一种记录大脑神经元电活动的生理信号，通过在头皮上放置多个电极，测量和记录大脑皮层的电位变化，为观察和分析人脑活动提供了重要的无创测量工具。EEG 具有卓越的时间分辨率，体现在其可以实时记录大脑神经元的电活动，并以毫秒级的精度捕捉到脑区活动的快速变化，被广泛应用于神经科学、认知科学、临床医学和脑机接口等领域[4]。虽然功能性磁共振成像（functional Magnetic Resonance Imaging，fMRI）也是一种研究脑部疾病的重要方法，但是由于在专业知识、专用设备和高成本方面的大量要求，以及在扫描仪之间协调 fMRI 采集的挑战，其临床实用性就大打折扣了。相比之下，EEG 的成本更低，且对于不同的临床环境具有良好的普适性，因此对于脑部疾病研究和临床指导更加实用[2]。

开展本研究具有重要意义。从理论上讲，有助于深入理解 MDD 的神经生理机制，揭示大脑在病理状态下的电活动变化规律，为 MDD 的发病机制研究提供新的视角。在实践方面，该研究有望为临床提供一种客观、无创且高效的 MDD 辅助诊断工具，尤其在传统主观问卷评估存在局限的情况下，能够有效提高 MDD 的早期识别率。通过构建基于脑电的智能分类模型，医生可在就诊初期获取量化的辅助判断依据，从而实现更早期的干预和更个性化的治疗方案。这不仅有助于改善患者的治疗效果和长期预后，也有望降低 MDD 带来的社会医疗成本，减轻患者家庭和社会负担。

1.2 研究现状

MDD 的主要特征体现在人的情绪上，而人的情绪来源于大脑，因此学者们将研究方向确定在患者的大脑，对患者的大脑展开研究。脑电图的优越性使其成为研究 MDD 的良好数据材料，研究人员从脑电图出发，分析 MDD 患者与正常人群，以及不同 MDD 患者之间的区别，并将脑电图的特征与人脑的结构相结合，探索 MDD 的发病机理和其亚型产生的原因。国内外学者运用机器学习（神经网络、聚类等方法）来研究 MDD 各亚型的动态模型和功能连接性（Functional Connectivity），用以区分不同亚型、研究 MDD 的发病机理和治疗 MDD 的手段。

EEG 用于诊断 MDD 的可靠性早已证明，Yasin 和 Sana 等总结了过去十年中使用神经网络处理 EEG 信号以检测 MDD 的研究[5]。作者强调了 EEG 作为识别 MDD 的生物标志物的潜力，并讨论了各种 EEG 协议、特征提取方法和公共数据集。他们建议未来的研究应注重提高模型的可靠性和准确性，以开发更具确定性的计算智能系统用于精神病学诊断[5]。治疗方面，Khodayari-Rostamabad 和 Ahmad 的研究提出了一种基于预处理 EEG 数据的机器学习方法，用于预测 MDD 患者对选择性 5-羟色胺再摄取抑制剂（SSRI）治疗的反应[6]。通过特征选择和混合因子分析模型，研究人员在交叉验证中达到了 87.9% 的预测准确率，敏感性为 94.9%，特异性为 80.9%。这表明 EEG 数据可用于个性化预测抗抑郁治疗效果[6]。

功能连接性在 MDD 诊断和亚型分析的作用十分重要。Chen H 等[7]在研究中使用动态功能连接性（DFC）分析了静息态 EEG 数据，以区分非精神病性 MDD（NPMD）、精神病性 MDD（PMD）和精神分裂症（SCZ）。研究发现，不同诊断组在 Delta、Theta 和 Gamma 频段的网络状态中存在显著差异[7]。使用这些 DFC 指标进行四分类（HC、NPMD、PMD、SCZ）时，分类准确率为 73.1%，优于静态功能连接性方法。这表明 DFC 可以作为识别精神障碍的动态网络生物标志物[7]。同样的，Mumtaz, W 等[8]提出了一个基于 EEG 同步性指标（Synchronization Likelihood, SL）为特征的功能连接框架，用于诊断 MDD。该框架利用 EEG 信号中的功能连接特征，结合支持向量机、Logsitic 回归等分类器，实现了对 MDD 患者的有效识别。研究强调了 EEG 功能连接性在 MDD 诊断中的重要性。此外，Duan 等基于 32 名受试者（16 MDD、16 HC）的 EEG，提取 Theta、Alpha、Beta 频段的结构性（功率谱、非线性）与连接性（互信息、交叉相关）特征，通过线性组合

获得混合特征输入分类器，比较了结构、连接与混合特征的分类效果。混合特征下，分类准确率为 94.13%，敏感性为 95.74%，特异性为 93.52%，F1 为 95.62%[9]。结果表明，不同类型特征互补性强，融合方法可提升 MDD 检测性能。李建秀在论文中从功能网络构建、时频分解、高阶超网络、治疗干预与空间分布四个方面入手，系统研究了 MDD 的脑连接异常模式与识别算法，提出了成本与拓扑结构权衡模型方法（Trade-off Model between Cost and I Topology under Role Division，MCT），全面梳理了 EEG 功能网络分析与抑郁识别的理论与实践，为临床辅助诊断提供了可靠方法与生物标志物[10]。

1.3 论文结构

本文分为四章，章节安排如下：

第一章，绪论。本章介绍了 MDD 的研究背景和研究意义，以及脑电图的简单工作原理和相较 fMRI 的优越性，同时指出了研究现状，阐明了研究动机。

第二章，研究基础和方法概述。本章重点介绍了基于ShallowConvNet的M-ShallowConvNet模型。详细介绍了ShallowConvNet和M-ShallowConvNet两者的网络结构和相关参数，并比较了两者在结构上和超参数上的区别，指出了M-ShallowConvNet相较于ShallowConvNet的提升之处。接着，本章还对聚类方法进行了介绍，对手肘法、轮廓系数法、K-means聚类方法的思路和数学原理都进行了详细说明。此外，本章还对实验部分使用的数据集TDBRAIN进行了介绍，指出该数据集的优越性以及数据的预处理流程。

第三章，基于 M-ShallowConvNet 的 MDD 诊断。本章主要介绍了实验设计的思路、实验方法并对实验结果进行分析。首先，本章对数据集进行了分析，解释了数据集的组成和划分依据；同时，本章给出了实验的详细流程；最后，本章对实验结果进行了详细分析，得出 High Gamma 频段为 MDD 组与 HC 组的最佳分类频段的结果。

第四章，MDD 群体的亚型分析。本章首先介绍了使用的数据集并介绍了聚类与可视化方法；接着，本章介绍了实验流程；最终，本章对聚类结果进行可视化，并且绘制了两个亚型的脑区热力图以及功能连接性矩阵进行分析。

最后，对全文内容进行总结，并提出对 MDD 诊断和划分亚型研究的未来展望。

第二章 研究基础和方法概述

2.1 脑电神经生理学基础

EEG 信号的产生和测量：大脑中的单个神经元或神经纤维放电会产生微弱的电位，而外部记录的脑电图（EEG）反映的是成千上万甚至数百万个神经元或纤维同步放电所产生的电位总和。因此，EEG 信号的强度主要取决于同步放电的神经元和神经纤维的数量[11]。脑电活动通常由外部刺激或事件引发，这些刺激或事件可以通过精心设计来激活特定的脑区，如视觉、听觉和体感皮层，从而使相关的 EEG 测量广泛应用于这些功能区的研究。

EEG 信号的特点包括：具有很高的时间分辨率（毫秒级），但空间分辨率较差，这一缺陷主要来源于有限的空间采样和头部容积传导效应。正是由于这些特性，EEG 信号的研究需要依赖先进的脑电成像技术，以弥补空间分辨率的不足。

2.2 脑电与抑郁症的关系

MDD 与脑电活动之间存在着密切的关系。通过脑电图（EEG）可以观察到 MDD 患者在脑电波频率、区域活动及其左右脑不对称性等方面的异常。

2.2.1 脑电频段与抑郁症的关联

MDD 患者的脑电活动在多个频段和脑区均表现出显著异常，这些神经电生理特征为情绪低落、思维迟缓及认知功能障碍提供了客观标志。研究发现，MDD 患者在前额叶区域的 Alpha 波（8–13 Hz）功率显著低于健康对照，这与情绪低落及动机缺失密切相关。Van der Vinne 等人通过汇总 300 例以上研究数据的 Meta 分析指出，MDD 组的前额叶 Alpha 波不对称（Frontal Alpha Asymmetry，FAA）总体效应值显著偏右，即左额叶 Alpha 波功率减少[12]。此外，多项研究报告发现，MDD 患者在 Theta 波（4–8 Hz）与 Delta 波（0.5–4 Hz）频段的功率升高：Spironelli 等在成年 MDD 群体中发现，清醒状态下 Delta 与 Theta 波功率普遍高于对照组，并随 HAM-D 评分上升而增强[13]。临床研究进一步指出，ACC 区域的 Theta 波功率升高与认知调节能力减弱及药物疗效预测相关[14]。网络层面上，基于 PLI/PLV 的功能连接分析揭示，Delta 及 Alpha 频段的全脑同步性

在抑郁组与健康对照间存在差异[15]。新的脑电网络构建方法进一步证明，多频段、多方法融合可提升 MDD 诊断与分型的准确性[16]。尽管目前尚无统一的脑电生物标志物能用于 MDD 的诊断，但脑电图作为一种研究工具，已被广泛用于探讨 MDD 的神经机制，并可能为未来的诊断和治疗提供新的方向。

2.2.2 基于脑电的抑郁症辅助诊断方法

脑电的频谱特征分析是脑电诊断或分类不同亚型的一种重要方法，脑电图信号可以通过分析不同频段（如 Delta、Theta、Alpha、Beta 等波段的活动）来识别 MDD 的特征。不同的亚型可能表现出不同的频谱特征。其中：

Delta 波（0.5-4 Hz）：通常与深度睡眠、放松、精神疲劳相关，MDD 患者可能在这一频段有异常的增加。

Theta 波（4-8 Hz）：在一些亚型中，此波的活动可能会显著增加，尤其是在情绪控制困难的个体中。

Alpha 波（8-13 Hz）：此波的活动与放松和愉悦感相关。MDD 患者常表现出 Alpha 波的抑制，尤其是在前额区。

Beta 波（13-30 Hz）：该波的增加可能与焦虑、紧张等情绪状态相关，一些 MDD 患者可能表现出这一频段活动的变化。

通过对这些频段的功率谱进行分析，可以对 MDD 患者进行不同亚型的区分。例如，某些亚型可能呈现出 Theta 波的显著增强，而其他类型则可能在 Alpha 波或 Beta 波上表现出显著差异。

此外，相空间分析方法（Phase Space Analysis）也是基于脑电辅助诊断 MDD 的一个方法。相空间分析方法通过对脑电信号的相空间重建，分析脑电图的非线性特性。该方法能够揭示脑电信号的复杂性和动力学模式，适用于检测亚型[17]。

再者，基于连接性分析的方法（Connectivity-Based Methods）也是一个非常主流的研究方法。其中包括脑网络分析（Brain Network Analysis）和功能连接性（Functional Connectivity）的研究。其中，脑网络分析（Brain Network Analysis）借鉴图论（Graph Theory）和复杂网络理论，将大脑看作由节点（脑区或电极位置）与边（节点间的结构或功能连接）构成的网络系统，对其拓扑结构进行量化与比较。具体而言，首先需要根

据时频信号（如 EEG 或 fMRI 时间序列）计算各节点之间的相关性指标（如皮尔逊相关、相位锁定值 PLV、互信息等），并将所得矩阵经过阈值化或加权处理，生成二值或加权网络。接着，利用网络度（Degree）、聚类系数（Clustering Coefficient）、最短路径长度（Path Length）和全局效率（Global Efficiency）等度量，评估大脑网络的局部集群特性与整体信息传输效率；同时，可通过模块度（Modularity）检测网络的功能分区，通过枢纽节点（Hub）和“富集俱乐部”（Rich Club）分析识别对网络整合与高效通信至关重要的关键节点。此外，动态脑网络分析（Dynamic Network Analysis）逐渐兴起，通过滑动窗口或时序分段技术刻画网络结构随时间的重构与转换来捕捉认知任务、病理状态或药物干预下的大脑功能重组过程。这些图论指标不仅可用于正常发育与老化过程的研究，也为诸如阿尔茨海默病、抑郁症、癫痫等神经精神疾病的早期诊断与疗效评估提供了可量化的生物标志物。由于脑功能连接主要是通过计算成对的感兴趣区域（Region Of Interest, ROI）之间的相关性来进行构建的，因此在建立大脑的功能连接网络之前，需要对大脑进行 ROI 的划分。在脑电信号处理中，研究人员通过多种方法（如相关性分析、相位同步、Granger 因果关系等）来评估功能连接性，以揭示大脑在不同认知任务或情绪状态下的网络活动模式。

这些方法不仅能提高我们对脑功能的理解，还能在临床诊断和认知障碍等疾病研究中发挥重要作用。不同亚型的患者可能表现出不同的连接性模式。例如，MDD 患者可能表现出前额皮层与其他脑区之间连接性的减少，或者某些脑区之间的过度同步。然而对于脑电图的功能连接性分析，不同空间通道的脑电图信号或其源估计会受到由电场扩散（即体积传导）导致的人工方差影响，而且源定位方法的空间分辨率有限，这些因素会干扰利用在头皮上采集的静息状态脑电图以准确的方式提取神经模式，也就是功能连接性。为了解决这个问题，研究人员采用了功率包络连接（Power Envelope Connectivity，PEC)，它能准确估计脑磁图中自发振荡活动的相关结构，然后在脑电图中进行验证。PEC 估计通过正交化去除零相位滞后（即非生理同时发生）的信号，减轻了由体积传导引起的伪相关[2]。

2.3 模型选择与聚类方法

2.3.1 模型选择依据

基于 TDBRAIN 数据集的现有工作有：

Lemaitre 等构建患者特异的动态网络模型，利用 TDBRAIN 数据集中 118 名 MDD 患者的短时静息态 EEG，捕捉脑区间如何相互影响的时变网络特征[18]；他们还提出“sink 指数”（sink index），量化某脑区在网络中作为信息“汇聚”或“扩散”节点的能力，探讨其与抑郁严重程度的关系[18]。他们发现 MDD 患者的网络动力学模式呈现独特变化，sink 指数与抑郁评分显著相关，表明该指标可作为抑郁严重程度的潜在生物标志物；同时，网络模型方法有助于发现传统功率谱和非线性特征难以揭示的动态连接异常，为 EEG 驱动的抑郁诊断开辟新路径[18]。

在数据预处理方面，Eleonora 比较了 TDBRAIN 预处理 Pipline（原始 TDBRAIN、DISCOVER-EEG、Automagic）对 Logsitic 回归、SVM 等模型的影响，并分析不同预处理阶段对特征提取与分类性能的贡献[19]。此研究发现，预处理流水线选择显著影响模型性能：Automagic（包含自动伪迹检测+插值）在平均 F1 上优于仅滤波和 DISCOVER-EEG。然而，尽管过度去伪迹可提高信号质量，但部分伪迹成分可能携带诊断信息；需在去伪迹与保留关键特征间权衡，以优化分类效果[19]。Liem 等人回顾了 EEG 预处理、特征工程与机器学习在 MDD 生物标志物发现中的技术与临床挑战并涵盖对包括 TDBRAIN 在内的多中心 EEG 数据集的预处理流水线比较、伪迹去除策略与特征提取方法对分类性能的影响[20]。该研究发现不同预处理流程（滤波、ICA、伪迹校正）对最终分类准确率有 10-15%的波动影响，建议针对 TDBRAIN 等大规模临床数据，开发统一且可复现的自动化预处理流程，以提升模型的泛化性[20]。

MDD 诊断方面，Liu 等人针对跨被试差异，提出 MDD-DAL 框架，将空间-时间 Transformer 用于 EEG 特征提取，并引入对抗学习模块以对齐不同被试域之间的数据分布[21]。在 TDBRAIN 数据集及 Mumtaz2016 数据集（闭眼/开眼任务）上进行对比实验，验证模型的泛化性能。空间-时间 Transformer 模块有效提取 EEG 时空特征，对抗学习显著提升跨被试分类的稳健性，模型在 MDD/HC 分类中取得优异效果（准确率最高可达 94.8%）[21]。该结果表明，结合域对抗策略的网络架构可缓解个体差异带来的泛化难

题，为大规模多中心 EEG 应用提供可行方案。此外，Umair 等引入分割式学习（Split Learning）框架，将模型分为本地端与服务器端，既保证数据隐私，又能共享中间表示进行联合训练[22]。特征提取方面结合 Transformer 深度网络与传统机器学习（决策树、KNN、SVM、梯度提升、随机森林），并在本地端抽取深层特征，在服务器端融合优化最终分类模型。此研究发现，在集中式训练设置下，Transformer 与随机森林的结合获得了 99%的分类准确率[22]。在采用 Split Learning 框架时（数据分散在三台客户端，本地训练后仅交换中间表示），表现最好的那个客户端也达到了 96.23%的准确率，验证了该框架在满足临床数据隐私法规前提下，能够保持与集中式训练相近的性能[22]。该研究中的其他方法的准确率[22]如下：Transformer +决策树为 88%、Transformer + KNN 为 92%、Transformer +SVM 为 93%、Transformer +梯度提升为 95%。

综上，基于 EEG 的 MDD 方面研究的工作有很多，但是基于 TDBRAIN 数据集的工作相对较少。在现有基于 TDBRAIN 数据集相关的研究中，大部分工作都是聚焦于数据集描述、预处理和跨中心对比，只有少数工作是针对 MDD 与 HC 分类展开的。在仅有的分类任务中，分类效果很好的工作都是使用 Transformer 来进行 EEG 特征提取进行训练。虽然 Transformer 具备强大的长程依赖建模能力，这种方法在基于 EEG 的 MDD 诊断方面仍然存在一定的局限性：首先，Transformer 的计算与存储开销比较大。EEG 通道数较多，再加上长序列，注意力矩阵规模进一步放大，显著增加显存占用，训练时常常面临“显存溢出”风险[23]。其次，TDBRAIN 数据集的样本数相对较少。EEG 信号的高维稀疏性和噪声特征，使得包含数千万参数的 Transformer 在仅一百多位受试者的 MDD/HC 数据集上极易陷入过拟合[24]。还有，Transformer 具有黑盒性，不易融入领域知识。虽然自注意力机制可以部分了解特定研究的某个脑区，但整体模型仍然缺乏便于临床解读的可视化解释工具，不利于医学专家信任和采纳[25]；而且，医疗诊断中常需结合已知的频段或通道分区知识（如 Alpha 波不对称），而纯 Transformer 架构难以在模型结构中直接加以强制融入[26]。值得注意的是，除了 Transformer 参与训练的问题外，目前效果良好的工作都没有对 TDBRAIN 数据集进行分频段分析，更没有根据频段分析结果进行 MDD 的亚型分析。因此，本研究旨在对 TDBRAIN 数据集进行不同频段下的 MDD/HC 分类，并找出诊断效果最佳的频段进行 MDD 的亚型分析。本研究没有选用大模型进行特征提取和训练，而是采用 ShallowConvNet 和 M-ShallowConvNet 这种适合中、

小样本与 EEG 特征提取解码的轻量级网络进行对比实验，并根据结果进行亚型分析。

2.3.2 聚类方法介绍

2.3.2.1 手肘法

手肘法用于确定聚类数 K 的“最佳拐点”。其核心思想是：在每一次聚类都计算出最后达到的簇内误差平方和 $J_e(K)$。随着 K 增大，$J_e(K)$ 会不断下降，但当 K 过大时，降幅变缓，曲线出现“肘部（elbow）”——该点对应的即为推荐值[27]。

簇内误差平方和 $J_e(K)$ 定义为：

$$J_e(K) = \sum_{j=1}^{K} \sum_{x_i \in C_j} \| x_i - \mu_j \|^2 \tag{2.1}$$

一般给 K 赋值（根据样本的可分性和大小或经验），然后计算完 K 对应所有的 $J_e(K)$，作 K 为横轴，$J_e(K)$ 为纵轴的折线图，然后寻找拐点位置，即 $J_e(K)$ 降幅从快速变为平缓的转折处即为最佳聚类数 K。手肘法直观易用，但对拐点判定依赖视觉，主观性较强，因此本研究还引入轮廓系数法，将两种方法结合，对最佳聚类数 K 进行双重确认。

2.3.2.2 轮廓系数法

轮廓系数（Silhouette Coefficient）结合了聚类的凝聚度（Cohesion）和分离度（Separation），用于评估聚类的效果。轮廓系数的值处于 $[-1,1]$ 之间，值越大，表示聚类效果越好。

对样本 x_i 定义：

1. $a(i)$：样本 x_i 与同簇内其它样本的平均距离（簇内紧密度）

$$a(i) = \frac{1}{|C_{j(i)}| - 1} \sum_{\substack{x_p \in C_{j(i)} \\ p \neq i}} \| x_i - x_p \| \tag{2.2}$$

2. $b(i)$：样本 x_i 与最近的其它簇的平均距离（簇间分离度）

$$b(i) = \min_{\ell \neq j(i)} \frac{1}{|C_\ell|} \sum_{x_q \in C_\ell} \| x_i - x_q \| \tag{2.3}$$

3. 轮廓系数：

$$s(i) = \frac{b(i) - a(i)}{max\{a(i), b(i)\}} \tag{2.4}$$

若 $s(i) \approx 1$ ，说明样本 $s(i)$ 聚得很合理；

若 $s(i) \approx 0$ ，说明样本位于两个簇边界；

若 $s(i) < 0$ ，说明样本可能被分错簇。

对整个簇的评价可取其内样本平均轮廓系数：

$$\bar{s}(K) = \frac{1}{n}\sum_{i=1}^{n} s(i) \tag{2.5}$$

遍历不同 K，计算 $\bar{s}(K)$，选择使其最大的 K 作为最佳聚类数。

2.3.2.3 K-means 聚类

K-means 是一种将样本划分到 K 个簇中的经典划分式聚类算法，其目标是最小化各簇内样本到簇中心的平方欧氏距离之和。假设数据集为 $X = \{x_1, x_2, \dots, x_n\}$，每个$x_i \in R^d$，簇中心为 $\{\mu_1, \dots, \mu_K\}$，则优化目标为：

$$\min_{\mu_j, C_j} J = \sum_{j=1}^{K} \sum_{x_i \in C_j} \| x_i - \mu_j \|^2 \tag{2.6}$$

其中，C_j 为第 j 个簇的样本集合，$\mu_j = \frac{1}{|C_j|} \sum_{x_i \in C_j} x_i$ 是该簇的样本均值。

算法流程简要为：

1. 随机（或借助 K-means++）初始化 K 个中心 $\{\mu_j\}$（本研究采用手肘法和轮廓系数法确定 K）。
2. 分配，将每个样本分配到最近的簇中心：

$$Assign\ x_i \to C_j\ where\ j = ar\,g \min_{1 \le t \le K} \| x_i - \mu_t \|^2 \tag{2.7}$$

3. 更新，对每个簇 j，重新计算其中心：

$$\mu_j \leftarrow \frac{1}{|C_j|} \sum_{x_i \in C_j} x_i \tag{2.8}$$

4. 重复步骤 2—3，直至簇中心收敛或达到最大迭代次数。

2.4 TDBRAIN 数据集

2.4.1 数据集介绍

本研究所用的 TDBRAIN（Two Decades Brainclinics Research Archive for Insights in Neurophysiology）数据集是一项由 Brainclinics 实验室自 2001 年至 2021 年期间常规临床和应用神经科学项目中累积的多年记录，旨在为神经生理机制研究和生物标志物开发提供大规模、高质量的原始 EEG 数据资源。数据集包含 1274 名参与者（620 名女性，占 49%，年龄范围 5–88 岁，平均 38.7±19.2 岁），共计 1346 次 EEG 会话（含重复采集样本），参与者群体异质，既包括健康人群对照组（Healthy Controls，HC），也覆盖多种主要精神/神经疾病：MDD 及合并症（426 人，仅患有 MDD 的患者共 132 人）、注意缺陷多动障碍（ADHD，271 人）、主诉记忆障碍（SMC，119 人）、强迫症（OCD，75 人），以及其他未诊断或小众疾病患者[28,29]。

采集协议与设备方面，所有受试者均在安静标准化实验室环境中进行静息态（resting-state）EEG 记录，包含闭眼和开眼各 2 分钟，使用 Compumedics Quickcap 或 ANT-Neuro Waveguard 头箍（26 个 Ag/AgCl 电极，10–10 国际系统布局）进行脑电采样，采样频率为 500 Hz。此外，同步记录 5 个 EOG（左右水平、上下垂直）、1 个颏肌 EMG（咬肌）、1 个 ECG（锁骨位置），所有通道均以平均乳突（A1/A2）作参考，AFz 作接地[29]。

TDBRAIN 不仅提供了原始时序 EEG，还包含丰富的人口学与临床信息（性别、年龄、身高、体重、睡眠质量、教育水平、酒精及药物使用史、NEO-FFI 五大性格问卷条目级数据等）、行为任务数据（听觉 Oddball、视觉 1-back）、以及自主神经测量（心电图 ECG）。部分参与者还配合经颅磁刺激（rTMS）或神经反馈（neurofeedback）治疗，其治疗结果和参数也一并收录，以支持诊断与预后生物标志物开发[28]。

该数据集的异质性（大样本量、多疾病类型）和多模态信息（EEG、EOG、EMG、ECG、行为及问卷）使其成为研究精神障碍发病机制、训练机器学习 / 深度学习分类器、以及探索新的诊断或预测性神经生物标志物的理想资源。

因此，本研究采用此高质量数据集，对不同频段在 MDD 识别中的验证其相对价值，试图在 MDD 内部发现了潜在的分型规律，为抑郁症精准干预和生物标志物挖掘做贡献。

2.4.2 数据预处理

TDBRAIN 中的原始 EEG 数据存在许多冗余信息，需要对其进行预处理，本研究的数据预处理流程如下：

首先，从原始 CSV 格式的 EEG 信号中读取电压值，并将其转换为以伏特为单位的多通道时间序列，以便与 MNE-Python 的处理接口兼容。

随后，基于标准 10–05 电极布局（standard_1005），筛选出与该布局匹配的有效通道，该标准会直接去掉无关的眼电通道（例如 'VPVA'、'VNVB'、'HPHL' 等），并为数据分配相应的空间位置信息和 1 kHz 的初始采样率。为了减少计算量并聚焦目标频段，我们将信号重采样至 250 Hz，并采用 50 Hz 工频及其谐波的陷波滤波去除电源噪声，再对不同的脑电频段实施带通滤波，带通参数由不同频段分布范围确定。

接下来，通过计算每个通道的标准差并设定为全体通道标准差平均值加两倍标准差的阈值，自动检测并标记异常通道，随后采用空间插值方法对其进行修复。清洗后的连续数据被划分为每段 2 s 的固定长度 epoch，使用幅值门限（500 μV）剔除高幅运动或肌电伪迹影响的 epoch。针对剩余干净的 epoch，我们采用平均参考法（average reference）并投影至数据中，以强化全头空间信息的一致性。

最后，应用基于信息最大化（infomax）算法的 ICA 分解（15 个独立成分）去除残留的眼电、肌电伪迹，并将处理后的 epoch 以 FIF 格式保存，用于后续的特征提取与分类分析。整个流程在遍历每位受试者的所有会话时，会自动跳过已处理完成的文件，确保高效完整地生成针对每个受试者与会话的标注良好、去噪齐备的各个频段的 epoch 数据。

第三章 基于 M-ShallowConvNet 的 MDD 诊断

本章首先针对 TDBRAIN 数据集中 MDD 与 HC 样本的分布特点，设计并构建了基于 ShallowConvNet 及其改进版本 M-ShallowConvNet 的端到端诊断框架。具体流程包含对原始 EEG 信号的通道归一化与 Euclidean Alignment 预处理、时域与空域卷积层的特征提取、平方映射与对数池化的非线性变换，以及在损失函数中融入 Focal Loss 和采样平衡策略以缓解类别不平衡问题。在模型训练环节，采用 Adam 优化器、L2 正则化和 Dropout 等手段提升泛化能力，并在多频段（包括 Delta、Theta、Alpha、Beta、Low Gamma 和 High Gamma）下独立构建对比实验流程，以得到 MDD 诊断效果最好的频段。

3.1 模型介绍

M-ShallowConvNet 是基于 ShallowConvNet 通过局部的改进得到的[31]。M-ShallowConvNet 相较原模型显著地提升了对原始 EEG 信号的解码性能。因此，本文将从最基础的 ShallowConvNet 开始介绍。

ShallowConvNet 最早由 Schirrmeister 等人提出，模仿经典滤波器组空间模式（FBCSP）设计，通过两层卷积（时域卷积+空域卷积）、平方激活与对数池化的组合，实现对原始 EEG 波形的端到端特征提取和分类，该网络因结构简单、参数量少，在多项运动想象数据集（BCI competition IV dataset 2a, High-Gamma Dataset）上表现稳定[30]。该网络的核心步骤示意图如图 3-1 所示[30]。

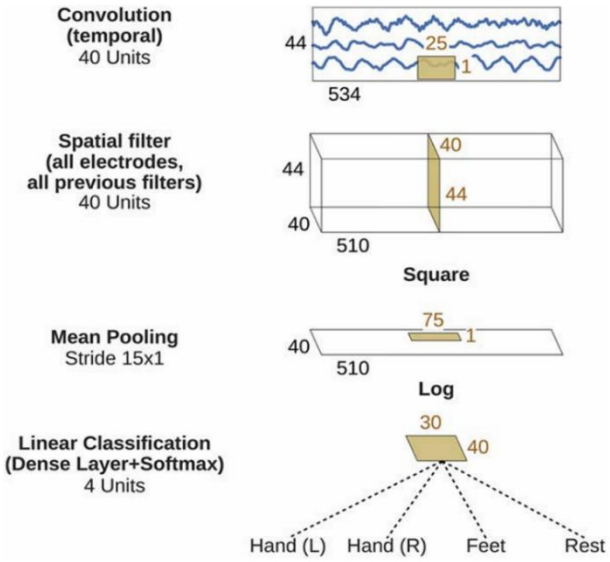

图 3-1 ShallowConvNet 的核心步骤示意图

ShallowConvNet 的从输入到输出的整个流程包括：时域卷积 → 空域卷积 → 平方非线性 → 平均池化 → 对数变换 → 全连接 + Softmax 分类。本文将详细完整地对 ShallowConvNet 进行解构，包括输入形式、各中间层的计算、输出及对应的数学公式。

该网络的输入将原始 EEG 信号表示为矩阵：

$$X \in R^{E \times T} \tag{3.1}$$

其中 E 是电极数，T 是每个 trial（实验段）的采样点数

下面对各层功能和模型流程进行介绍：

第一层（时域卷积）：卷积核大小为 1×25，沿时间维提取滤波器，相当于带通预处理。

第二层（空域卷积）：卷积核大小为 $E \times 1$，对所有电极进行线性组合，类似于 CSP 空间滤波。

第三层（平方非线性）：若第 2 层空域卷积输出为 $v_i[t]$，则

$$y_i[t] = (v_i[t])^2 \tag{3.2}$$

第四层（平均池化）：若窗口长设为 P，用以估计每个时间段内的平均能量，则

$$m_i[t] = \frac{1}{P}\sum_{\tau=0}^{P-1} y_i[t+\tau] \tag{3.3}$$

第五层（对数变换）：在变换基础上加入小常数 ε 保证数值稳定，有

$$z[t] = \log(m[t] + \varepsilon) \tag{3.4}$$

第六层（全连接+Softmax 分类）：对于一个 trial X，网络输出未归一化 $logits\{f_k(X)\}_{k=1}^{K}$，有

$$p(\, l_k \mid X\,) = \frac{\exp\big(f_k(X)\big)}{\sum_{m=1}^{K}\exp\big(f_m(X)\big)} \tag{3.5}$$

网络损失函数为交叉熵：

$$\mathcal{L} = -\sum_{k=1}^{K} y_k \log p(\, l_k \mid X\,) \tag{3.6}$$

其中 y_k 为 one-hot 真值标签。

此外，ShallowConvNet 还会在裁剪式训练（Cropped Training）中“绑定损失”，即对相邻裁剪窗口 $X_{t:t+T_0}$和 $X_{t+1:t+1+T_0}$，在普通交叉熵之上再加上相邻预测的一致性惩罚：

$$L_{tied} = L\left(X_{t:t+T_0}\right) - \sum_{k=1}^{K} log\left(p_k(X_{t:t+T_0})p_k(X_{t+1:t+1+T_0})\right) \tag{3.7}$$

Schirrmeister 等人基于 ShallowConvNet 的主要工作和贡献包括：首次证明了在被试内训练的深度 ConvNet（Deep ConvNet）可达到乃至略超滤波器组 CSP（FBCSP）的分类准确率。此外，该工作比较和验证了批归一化（Batch Norm）、Dropout、指数线性单元（ELU）、层次卷积方式等多种深度学习新技术对 EEG 解码性能的影响，发现这些技术对于提高准确率至关重要。再者，ShallowConvNet 中包含的裁剪式训练策略通过滑动窗口生成大量样本，能够显著提升 Deep ConvNet 在高频段上的准确率，并且研究人员也给出了高效实现方法。同时，该工作还开发了两种可视化方法，一个是输入特征－单元输出相关图：通过计算不同频段平均能量与中间层单元输出的线性相关，揭示网络学习的频谱特征分布。另一个是输入扰动－预测相关图：在频域中对输入幅度随机扰动并观测 Softmax logits 的变化，从因果角度验证频段特征对分类的影响。可视化结果显示网络确实学会利用 Alpha、Beta、Gamma 频段的带功率变化，并在人体运动皮层呈现合理的空间分布[30]。ShallowConvNet 的诞生无疑提高了 EEG 的解码和可视化工作效率和正确率，是神经网络在 EEG 解码分类邻域的一大重大突破。

然而，ShallowConvNet 具有两个主要问题：一是其超参数（时域卷积核长、池化窗口、滤波器数量等）在不同数据集上需要反复调优，二是部分卷积核在训练中几乎未被激活（表现为权重近零或偏负），导致训练不稳定和性能下降。为了解决这些问题，[31]提出了 M-ShallowConvNet，通过对 ShallowConvNet 做“小而必要”的四项改动：

首先，M-ShallowConvNet 重新设置了核心超参数，ShallowConvNet 默认使用 25 个采样点，M-ShallowConvNet 将其调整为 31（对应抗噪声优化后捕捉 mu 节律更合适）。滤波器数量方面，原版使用 40 条时域滤波器，M-ShallowConvNet 精简为 24 条，以避免过度拟合且减少未激活通道。

其次，M-ShallowConvNet 对池化层进行重新挑选。ShallowConvNet 默认“均值池化”（窗口 $k = 75$，步长 $s = 75$），而 M-ShallowConvNet 通过消融实验选定了更小的平均池化窗口，使得输出时间分辨率从 751 降至 31（即$k \approx 75$）。

接着，在原有模型的“平方非线性 → 平均池化 → 对数变换”三步之后，M-ShallowConvNet 加入了 Batch Norm。公式上，若池化输出为 z，则

$$\hat{z}_i = \frac{z_i - \mu_{\text{batch}}}{\sqrt{\sigma_{\text{batch}}^2 + \epsilon}} \cdot \gamma + \beta \tag{3.8}$$

其中，γ 和 β 为可学习的参数显著提升了训练稳定性与收敛速度。

此外，M-ShallowConvNet 还修正了无效参数。Kim 等指出原版 ShallowConvNet 存在未被训练或偏置过大的卷积核，M-ShallowConvNet 通过改进初始化（比如 Xavier/He 初始化）和移除无效偏置，确保每条滤波器在训练初期即具备有效梯度[31]。总之，M-ShallowConvNet 保留了 ShallowConvNet 的核心部分，只修改了部分结构和超参数，两者结构对比图如图 3-2 所示[31]。

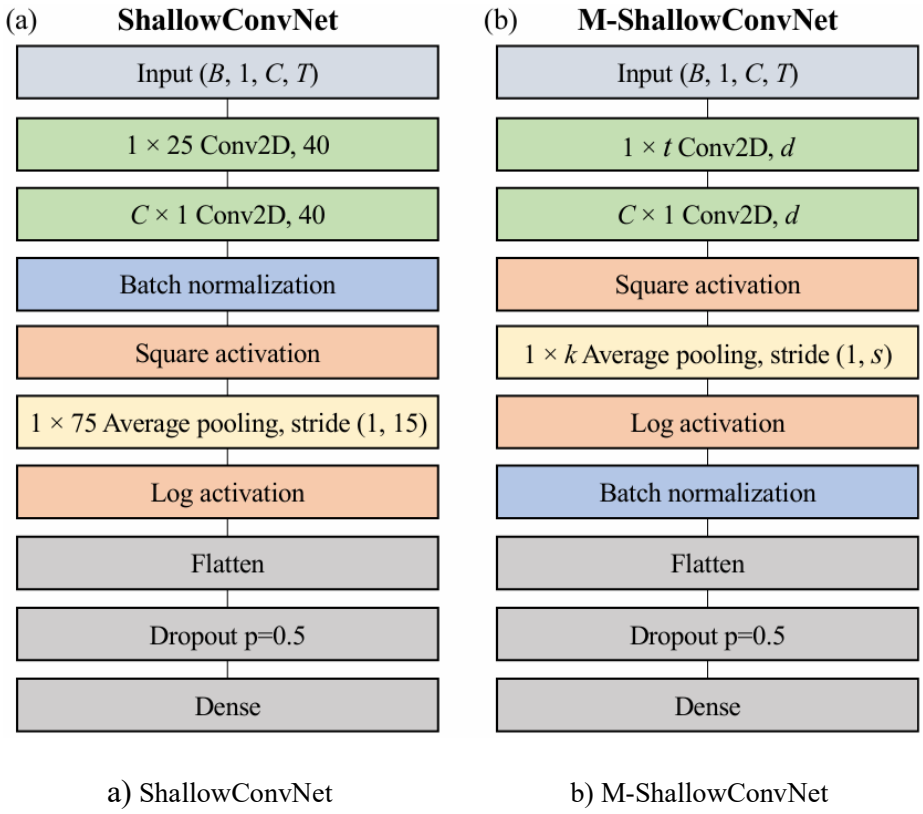

a) ShallowConvNet　　b) M-ShallowConvNet

图 3-2 ShallowConvNet 与 M-ShallowConvNet 的结构对比图

经过改进后的 M-ShallowConvNet 大幅提升了 BCI IV 2a/2b 两个四/二分类任务的平均准确率，从 0.765/0.855 提升至 0.8164/0.8647，同时训练过程更稳定、跨数据集泛化更好。M-ShallowConvNet 的优势在于仅在卷积核长、滤波器数、池化窗口、归一化策略等方面做“微调”，即可稳定提升准确率，并避免了大规模超参数搜索。而且，Batch Norm 与改进初始化同步解决了“梯度消失/爆炸”与“未激活通道”问题，使得跨多主体、跨多数据集的性能波动显著减小。再者，M-ShallowConvNet 在多种下游 MI-EEG 解码框架中

替换原有特征提取器都带来 2-3%的绝对提升，说明其通用性强。总的来说，M-ShallowConvNet 将神经生理学启发、现代归一化技术与精心调参结合，以“小成本”实现了对“经典”ShallowConvNet 在稳定性、泛化性和准确率上的全面优化。

3.2 实验设计

3.2.1 数据集分析

在挑选模型前，本研究针对数据集本身展开分析。读取标签信息后，经统计得 MDD 患者共 132 人，受试数约 3935 次；HC 仅有 47 人，受试数约 1400 次。因此，本研究的 MDD 诊断是典型的样本不均的分类任务。在解决样本不均的问题前，实验首先对各频段的两个数据集的可分性进行分析，即使用 t-SNE 进行数据降维和可视化。结果如图 3-3 所示（由于频段过多且分布相似，此处使用 Alpha 频段为例）。

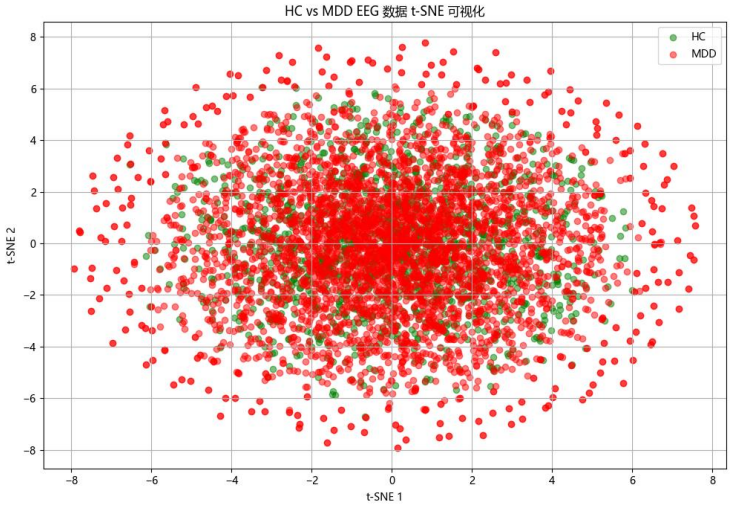

图 3-3 MDD 与 HC 的 t-SNE 结果

由图 3-3 可知，MDD 数据集与 HC 数据集的可分性很差，需要使用一定的训练方法才能得到可靠的训练结果。

3.2.2 训练方法

为解决 MDD 数据集与 HC 数据集的可分性问题，由于 ShallowConvNet 和 M-ShallowConvNet 在以往的 EEG 分类训练中表现良好，因此本实验选择 ShallowConvNet 和 M-ShallowConvNet 进行对比实验。

同时，在损失函数的选择上，本实验选用 Focal Loss。因为在二分类或多分类不平

衡问题中，标准的交叉熵损失（Cross-Entropy Loss）往往会因大量易分类样本（“负例”或“多数类”）主导梯度，导致模型训练偏向于多数类，难以关注少数类或难分类样本。为此，Lin 等人在 2017 年提出了 Focal Loss，通过在交叉熵基础上增加调制因子（modulating factor）和类别平衡权重，鼓励模型在训练中“聚焦”于难分类样本[32]。

Focal Loss 在以上交叉熵的基础上，引入两大改进：

1. 调制因子 $(1-p_t)^\gamma$，其中 $\gamma \geq 0$ 为聚焦参数（focusing parameter），当样本易分类时（p_t 较大，接近 1），$(1-p_t)^\gamma$ 很小，进而降低该样本的梯度权重；反之对于难分类样本（p_t较小），则保留较大权重。其中，

$$p_t = \begin{cases} p, & y = 1, \\ 1-p, & y = 0. \end{cases} \tag{3.9}$$

2. 类别平衡权重 α_t，用于缓解类别不平衡问题。通常对正负样本分别设定不同权重 α 与 $1-\alpha$。

因此，对单个样本，Focal Loss 可写为：

$$\mathrm{FL}(p_t) = -\alpha_t(1-p_t)^\gamma \, log(p_t) \tag{3.10}$$

其中，

$$\alpha_t = \begin{cases} \alpha, & y = 1 \\ 1-\alpha, & y = 0 \end{cases} \tag{3.11}$$

当 $\gamma = 0$ 且 $\alpha = 1$ 时，FL 退化为标准交叉熵损失。随着 γ 增大，易分类样本的损失下降更快，模型更“聚焦”于难分类样本。

在参数选择方面，γ（聚焦参数）推荐取值一般在 $[0,5]$ ，论文中常用$\gamma = 2$。值越大，对易分类样本的抑制越强，但过大会导致难分类样本也难以学习。α（平衡系数）用于调整正负样本的重要性。若正负样本比例为 π vs. $1-\pi$，可设$\alpha = \pi$。一般在训练时通过交叉验证确定最佳 α。

在解决样本不均的分类问题时，本实验没有采用数据增强类方法或 SMOTE 上采样对 HC 数据集进行扩充，这是因为本实验采用的是医学时序数据，不能自己凭空生成。采用上述方法生成的数据不像图像数据那样有很好的解释性，因而无法采用，只能使用原始数据进行实验。同时，训练时使用类别权重也不能很好地解决训练过程中模型对 MDD 人群的偏向性；而且模型在测试时即使全部分类为 MDD，也可以得到很高的准确率，这都是样本大小差距造成的。

因此，为了从根本上解决样本大小不平衡的问题，本实验采用采样训练的方法：即

先对 HC 数据集进行采样，随机抽取 80%的受试者作为训练集，剩下的 20%作为验证集。然后，对于 MDD 数据集不进行划分，而是直接随机采样，采样大小为 HC 训练集大小，即保证训练集中 HC 人群与 MDD 人群的比例为 1:1；剩下的 MDD 受试者与 HC 数据集中划分出的 20%作为训练的验证集。训练集与测试集成分如图 3-4 所示。

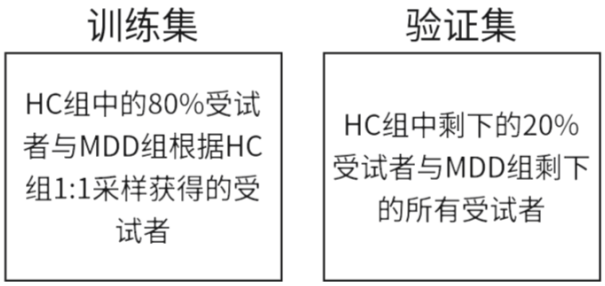

图 3-4 实验训练集与验证集的详细组成

需要注意的是，本实验并未划分测试集，第一是因为本身验证集的数量足够大且与训练集完全独立（MDD 组含有 132 人，HC 组仅含 47 人，用上述方法进行采样，验证集的受试数大小约为 3095，训练集受试数约为 2200），在这种情况下，验证集可以代替测试集去评估模型的泛化能力。而且，在 EEG 邻域的分类任务中，这种做法是有工作基础的，具有运动想象（MI）、情感识别、微睡眠和癫痫发作检测等不同应用场景，这些工作[33]-[37]都是将同一数据集按“会话”或“被试”完整划分出互不重叠的训练集和验证集，且往往将剩余大部分会话或被试作为验证集，使验证集样本量远超训练集。第二，由于本研究仅仅是利用对模型功能的复现来研究抑郁症分类问题，并未对模型进行结构改善或调参，因此本实验没有使用测试集去研究或衡量模型的泛化能力。第三，本研究所使用的数据集大小有限，如若按照标准的机器学习任务进行数据集划分训练集、测试集和验证集，可能会因为数据量过小导致训练效果不佳。而本实验选择构建验证集而不选择构建测试集是因为验证集能够看清每个 epoch 的趋势且重点在于对分类频段的研究，而不是模型的泛化能力。

3.3 实验流程

本实验训练步骤包括：标签筛选、数据读取与预处理、构建样本列表、训练/验证集划分与样本平衡、构造 PyTorch 数据加载器、M-ShallowConvNet（ShallowConvNet）模型结构定义、训练配置、模型训练与评估。各步骤详细过程（由于两个模型训练过程类似，这里只展示 M-ShallowConvNet 的训练过程）介绍如下：

Step 1：标签筛选

首先，从已有的实验数据文件夹中遍历所有被试编号，并读取包含所有被试信息和的标签文件（Excel 表格）。仅保留在本地文件夹中实际存在的数据对应条目，且其 formal_status 字段为“MDD”或“HEALTHY”的样本。最终构建一个映射表，将每个被试 ID 映射到二分类标签（HEALTHY→0, MDD→1）。

Step 2：数据加载与预处理

针对每个被试，依次读取所有会话（session）中的预处理后 EEG 数据文件，对每个受试 trial（epoch）保留原始时序数据不做均值压缩。对每个被试的所有 trial 应用 Euclidean Alignment（通过计算每个 trial 协方差矩阵并对其均值矩阵进行 Whiten 变换），随后对每个通道在被试内进行 z-score 归一化，以消除个体差异，同时保留频时信息。

Step 3：构建样本列表

将所有被试的 trial 按顺序展开，形成整体数据集。具体地，每个 trial 保持为 (n_channels, n_times) 的二维时序矩阵，并生成对应的标签列表和被试 ID 列表，用于后续分析。输出数据维度信息，包括总 trial 数量、通道数、时间点数，以及两类标签的 trial 数量分布和被试总数。

Step 4：训练/验证集划分与样本平衡

根据标签将 trial 分为 HC 与 MDD 两组，固定 HC 组中训练与验证集的划分比例，并通过随机打乱 MDD 样本后，截取相同数量的 MDD 样本用于训练，从剩余的 MDD 样本中构建验证集。最终保证训练集中两类样本数完全平衡，验证集中包括所有剩余的 MDD 样本与对应数量的 HC 样本。

Step 5：构造 PyTorch 数据加载器

在不丢弃时序信息的前提下，将每个 trial 作为一个样本送入自定义 Dataset 类。在 Dataset 中再次进行每个通道的 z-score 标准化，确保模型输入每个 batch 前都经过一致

处理。使用固定随机种子初始化 DataLoader，分别构造训练和验证加载器，训练加载器开启随机打乱，验证加载器按原顺序读取。

Step 6：M-ShallowConvNet 模型结构定义

设计并实现 M-ShallowConvNet 网络，包含时间卷积分支与空间卷积分支：

1. 时间卷积：对每个通道进行一维时间卷积并执行 BatchNorm、ELU 激活和 Dropout；

2. 空间卷积：在时间卷积输出上沿通道维度做空间卷积；

3. 平方映射与全局池化：对激活后的特征做平方运算，再做自适应平均池化，并取对数；

4. 全连接输出：将池化后的特征展平后通过全连接层预测二分类概率。

Step 7：训练配置

采用带类别权重的 Focal Loss，使网络在优化时更加关注那些易被忽略的边缘案例，以应对轻度类别不平衡的困难样本。类别权重根据训练集中标签分布动态计算，以确保在计算损失时弱化易分类样本的影响、强化难分类样本的作用。优化器选用 Adam，提升收敛速度和稳定性。同时，在损失函数中加入 L2 正则化，对模型权重施加二范数惩罚，以约束参数规模并抑制过拟合风险，使得训练得到的模型在验证集上表现更加稳健。

Step 8：模型训练与评估

循环若干 epoch，每个 epoch 完成一次对训练集的前向和后向传播，并在验证集上评估指标：准确率（Accuracy）、灵敏度（Sensitivity）、特异度（Specificity）、F1 分数（F1 Score）、AUC（Area Under the Curve）、平衡准确率（Balanced Accuracy）。每完成一个 epoch，这些训练与验证阶段的指标均会被汇总并追加到结果列表中，并最终保存为 CSV 文件，便于后续绘图和分析。

整个训练流程如图 3-5 所示。

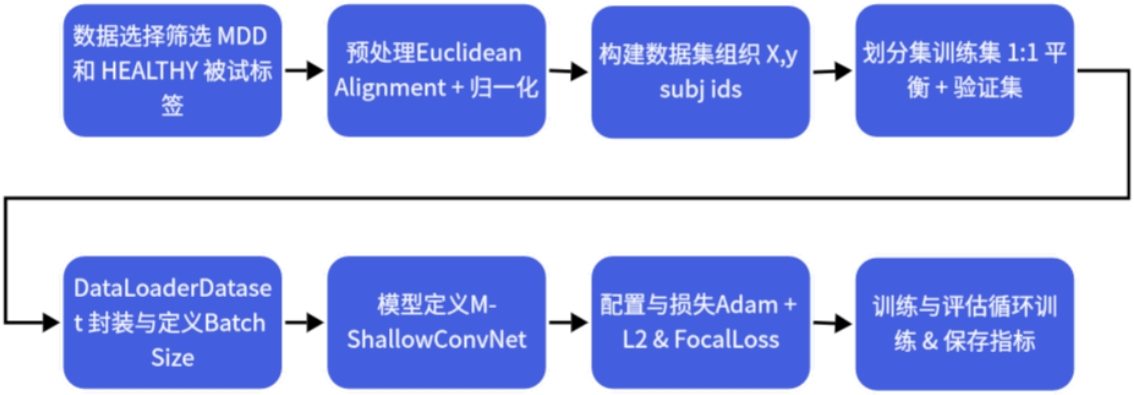

图 3-5 训练流程图

本实验选用了一系列经过验证的超参数来保证模型的稳定性与泛化能力。优化器方面采用了 Adam，以其自适应的学习率调整机制能够更快速地收敛；为了抑制模型过拟合，损失函数中引入了权重衰减，对参数施加 L2 正则化约束；同时，在卷积模块后使用了 0.5 的 Dropout 率，以随机屏蔽一半神经元、增强网络鲁棒性。最后，对于 ShallowConvNet，训练采用的是平均池化（AvgPool2d）的池化方式，而对于 M-Shallow-ConvNet，训练针对特征的空间维度，采用自适应平均池化（AdaptiveAvgPool）将其压缩至 1×1，大幅降低参数量并保留全局统计信息。训练使用的各个参数详情如表 3-1 所示。

表 3-1 训练参数设置

参数名称	ShallowConvNet	M-ShallowConvNet
优化器	Adam	Adam
学习率	$1e^{-3}$	$1e^{-3}$
权重衰减	$1e^{-4}$	$1e^{-4}$
Dropout 率	0.5	0.5
池化方式	AvgPool2d	AdaptiveAvgPool2d

3.4 实验结果

实验对 Delta、Theta、Alpha、Beta、Low Gamma（32-45Hz）、High Gamma（55-95Hz）六个不同的 EEG 频段使用 ShallowConvNet 和 M-ShallowConvNet 进行训练，对 MDD 人群与 HC 人群分类，ShallowConvNet 的 Loss 曲线和 Accuracy 曲线如图 3-6 和图 3-7 所示。M-ShallowConvNet 的 Loss 曲线和 Accuracy 曲线如图 3-8 和图 3-9 所示。

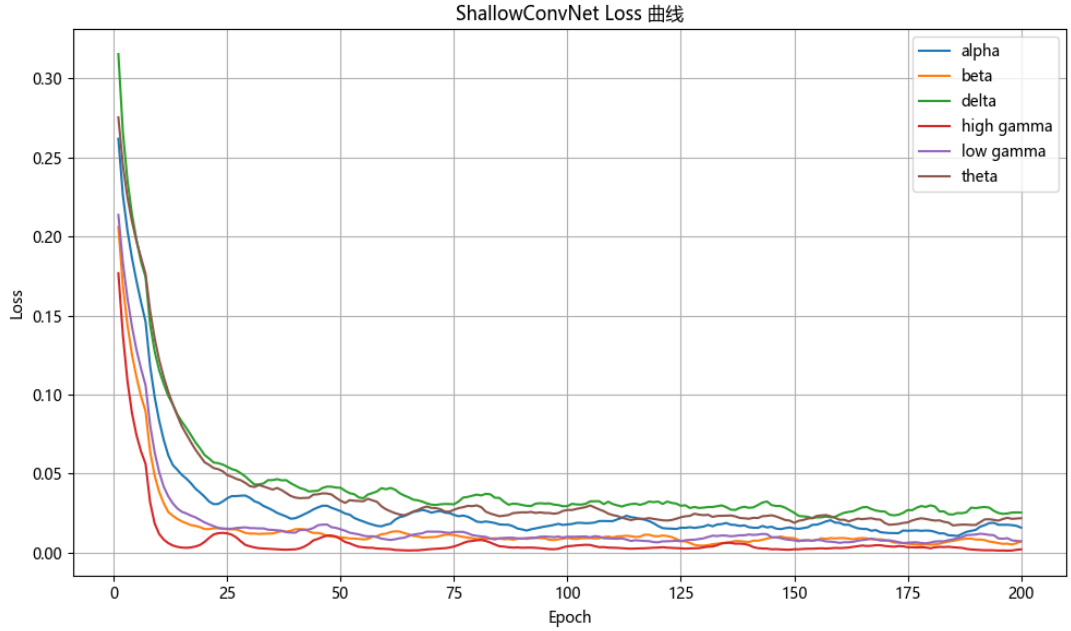

图 3-6 ShallowConvNet 的 Loss 曲线

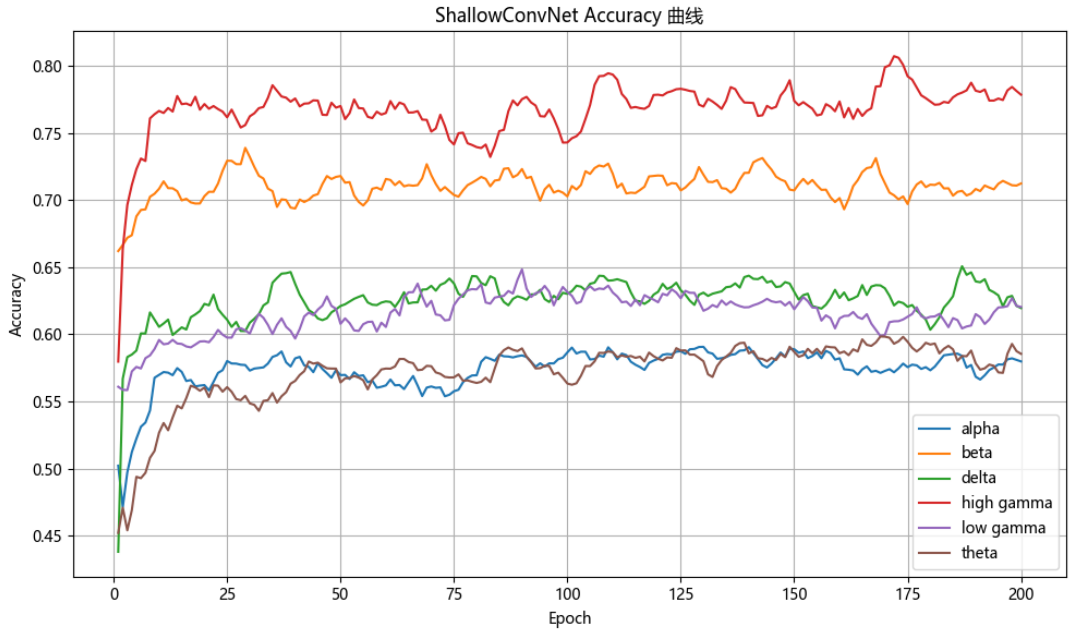

图 3-7 ShallowConvNet 的 Accuracy 曲线

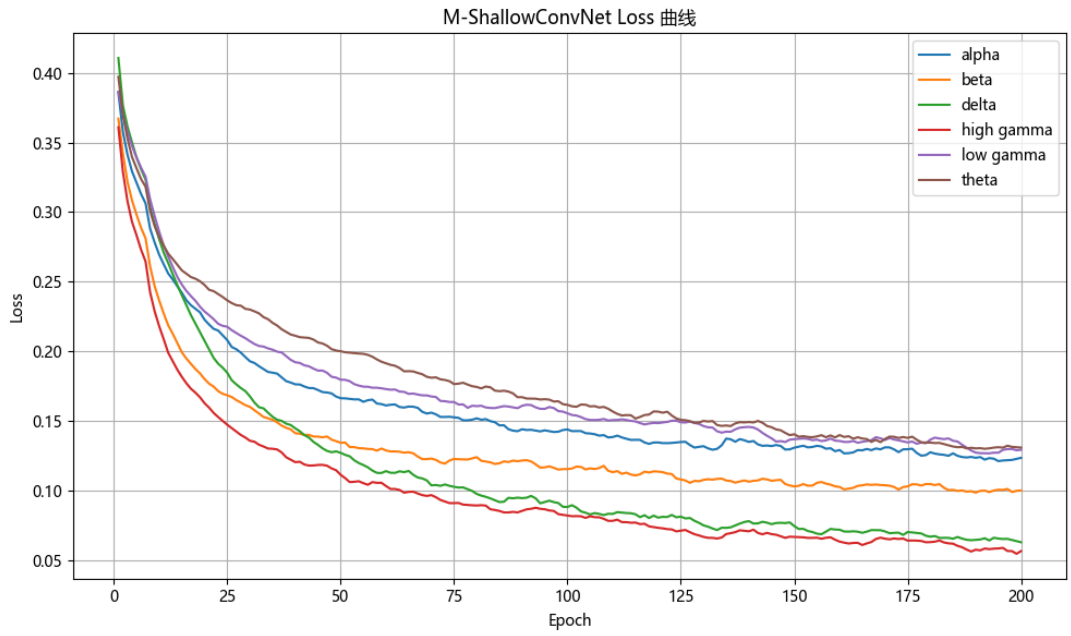

图 3-8 M-ShallowConvNet 的 Loss 曲线

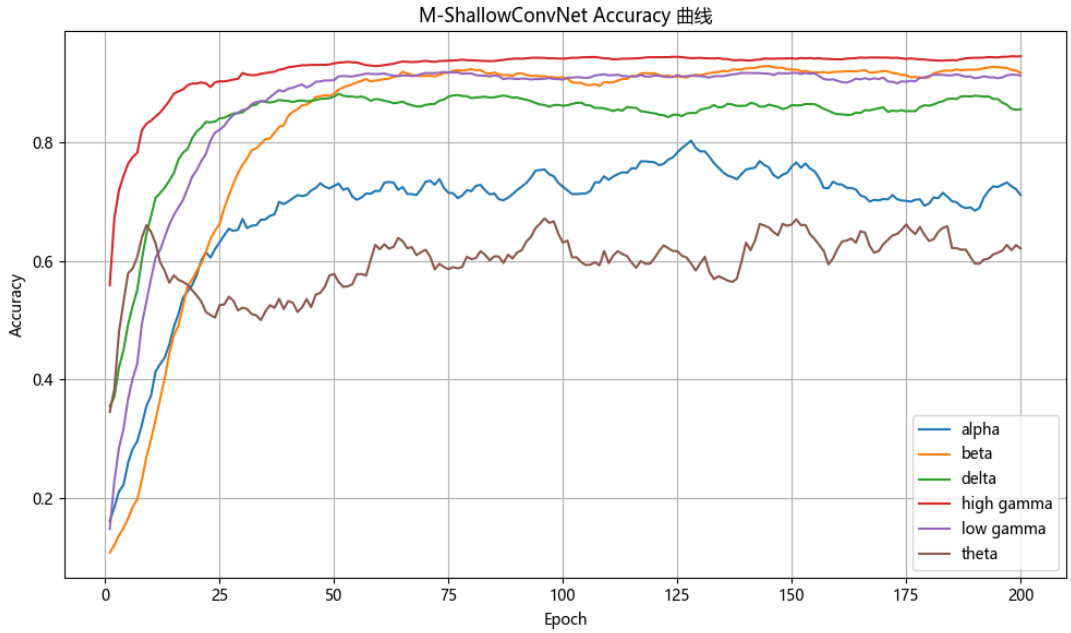

图 3-9 M-ShallowConvNet 的 Accuracy 曲线

由图 3-6 和图 3-8 可知，所有 Loss 曲线在训练初期均呈现快速下降趋势，随后逐渐趋于平缓并稳定收敛，没有出现明显的剧烈震荡。具体而言，以图 3-8 为例，High Gamma 的损失下降最快，在前 25 个 epoch 内迅速从约 0.36 降到 0.15 以下，并最终收敛到最低水平（约 0.065 左右），表明该频段模型训练误差最小、收敛速度最快。Delta 和 Beta 也表现出较快的损失下降，最终分别稳定在约 0.07 和 0.1 左右；相对而言，Alpha、Low Gamma 和 Theta 的损失下降较慢，最终收敛值分别约为 0.125、0.13 和 0.13 左右。各频

段在后期都出现了一些小幅波动，但整体上都比较平稳，没有明显的周期性震荡，说明训练过程稳定、均已基本收敛。

图 3-7 和图 3-9 中的 Accuracy 曲线则反映出各频段模型的收敛速度和最终分类性能差异。显而易见，M-ShallowConvNet 整体的分类准确率都要更高，收敛更快且更加稳定，由此可见该模型的优越性。具体而言，在图 3-7 中，High Gamma 准确率提升最快，大致在 50 个 epoch 左右便基本稳定，最高水平可达 80%以上，但是整体的浮动较大，稳定性较差；Beta 也在 50 个 epoch 左右趋于相对稳定，水平大约在 70-75%之间浮动；Delta 和 Low Gamma 的表现中等，准确率稳定在 60-65%之间，稳定性也很一般。Alpha 和 Theta 频段的表现最差，虽然水平大致能稳定下来，但准确率不高，在 55-60%之间徘徊。整体而言，虽然有部分频段（High Gamma、Beta）具有一定分类水平，但 Shallow-ConvNet 的分类准确率的稳定性都较差，收敛速度也较慢。

观察图 3-9 可知，High Gamma 准确率提升仍是最快，仅经过 25 个 epoch 便达到约 90%以上，并稳定在最高水平（最终在 95%左右）；Low Gamma 在 50 个 epoch 左右上升至约 88%，最终稳定在 90%左右。Beta 和 Delta 收敛速度次之，前者大约在 50 个 epoch 达到 85-87%，后者在约 50 个 epoch 达到 82-84%，此后 Beta 略有小幅波动但总体稳定在 90%左右，Delta 则在后期略有下降趋势，最终稳定在 82%左右。相比之下，Alpha 收敛最慢，精度在前 25 个 epoch 仅升至 60%左右，最终约在 70%上方震荡收敛（峰值约为 80%）；Theta 表现最差，不但最终准确率低，且训练过程中曲线起伏较大，先是小幅上升至 60%，再下降至 50%以下，后期又缓慢回升并在 60%左右不稳定波动。总的来看，Gamma 频段收敛最快且准确率最高，Beta 和 Delta 次之，Alpha 较慢而稳定在中等水平，Theta 频段收敛缓慢且波动明显、性能最差。

综合两个模型的损失和准确率指标，High Gamma 具有最优的分类效果：其最终损失最低、准确率最高（最高可达 95%左右），收敛速度也最快。这可能是因为 High Gamma 频段的振荡信号往往包含丰富的认知和情绪相关信息，已有研究表明 Gamma 频段活动在一定条件下能够区分 MDD 患者与健康对照，体现出其作为抑郁症标志的潜力[38]。因此,在本实验结果和相关研究的支撑下，可以说 High Gamma 提供了最具判别力的特征。Beta 频段的分类效果次之，其在中后期能达到较高的稳定准确率，表明该频段也含有较为有效的信号信息。相对而言，Alpha 频段的平均性能较弱，可能因为 Alpha 波主要反

映放松或闭目静息状态，其与抑郁状态的差异性有限，导致模型难以学习到足够的判别特征；综合两个模型，Theta 频段表现最差，平均准确率最低且不稳定，暗示低频 Theta 信号可能受噪声干扰较多或与抑郁相关性较低。值得注意的是，以往研究指出 Alpha、Theta 等低频段也能提供抑郁状态的信息[38]，但在本次分类任务中，这些低频信号的判别能力并不显著，或许需要结合其他特征或更复杂的模型架构才能发挥作用。

训练结果的敏感性、特异性、F1 分数、AUC 和平衡准确率指标如图 3-10 所示。

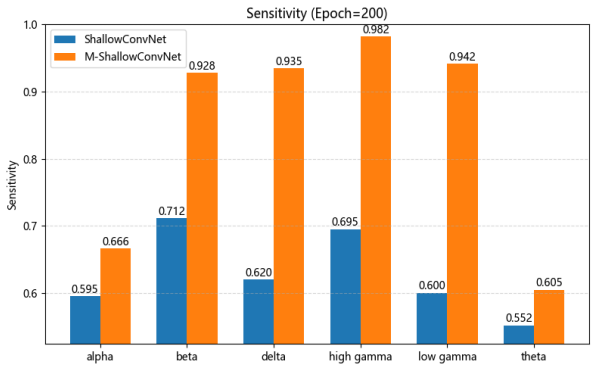

a) 敏感性

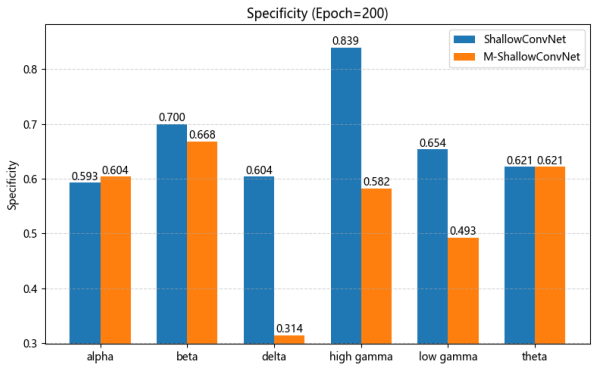

b) 特异性

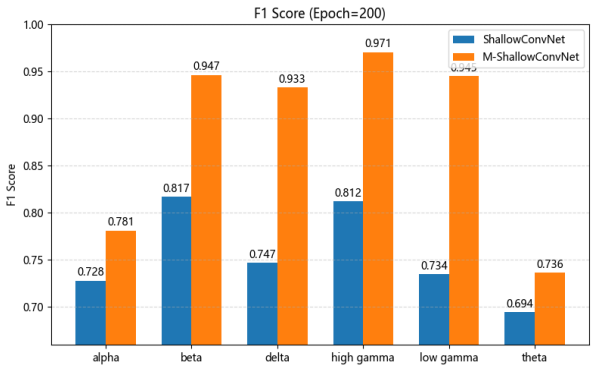

c) F1 分数

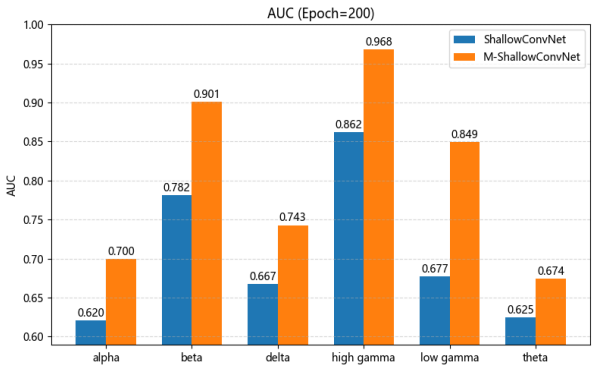

d) AUC

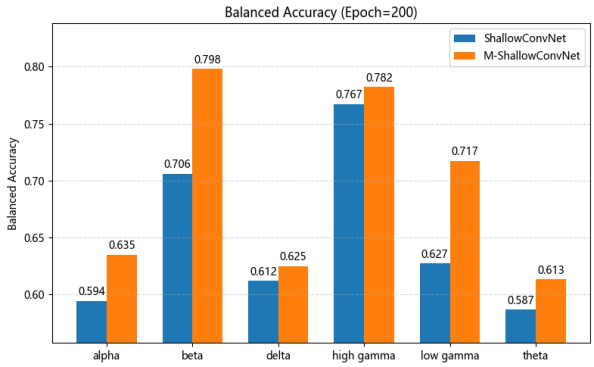

e) 平衡准确率

图 3-10 训练结果的各项指标

观察上图可知，M-ShallowConvNet 的特异性整体比 ShallowConvNet 弱，但其各个频段的敏感性比 ShallowConvNet 都要强。这表明 M-ShallowConvNet 倾向于以更积极的策略识别 MDD，以提升模型对潜在病患的敏感性和整体分类性能，故在某些边界样本上牺牲了少量 HC 样本的识别精度。这也可以解释为什么 M-ShallowConvNet 虽然在准确率上收敛更快、准确率整体更高、准确率曲线的稳定性更强，但它的 Loss 曲线整体对应的损失函数值要比 ShallowConvNet 的损失函数值更大：这是因为 Focal Loss 会对难分类样本赋予更大的“惩罚”，即更大的损失函数值，导致 M-ShallowConvNet 的损失函数整体提升。同时，M-ShallowConvNet 的特异性不高的原因可能是验证集中负样本稀缺，导致即使少量的负样本被误判，特异性指标也会骤降。

然而，由图 3-10 的 c)、d)、e)可知，M-ShallowConvNet 在 F1 Score、AUC 及平衡准确率等指标上均优于 ShallowConvNet，显示出其在抑郁症识别任务中更强的判别能力和泛化性能。此外，两个模型的 F1 Score 和平衡准确率并不低，说明模型都学习到了如何对两类样本进行划分，而不是根据验证集正负样本的巨大差距“盲猜”正样本来获得较高的准确率。况且，两个模型在相同频段的分类准确率相差较大，也能够说明模型不是靠“盲猜”来分类，而是学习到了相关特征，因为验证集中负样本数量远少于正样本：仅有约 280 个负样本（HC），而正样本（MDD）却高达 2815 个，如果是在每次分类时都预测为正样本，两个模型的各频段的准确率应该都是 90%左右。

综合所有指标，考虑到基于 EEG 的 MDD 诊断任务更关注 MDD 的检测能力，且 M-ShallowConvNet 的 F1 分数与 AUC 和 ShallowConvNet 相比显著提高，牺牲特异性换取极高的敏感性在实际应用场景中是可以接受甚至是必要的。因此，本研究认为 M-ShallowConvNet 在处理类别不平衡的临床 EEG 诊断任务中具有更高实用性。从各频段对比来看，High Gamma 频段综合表现均最为突出。虽然该频段的特异性在 M-Shallow-ConvNet 训练下只有约 0.58；相比之下，Beta 频段的特异性达到大约 0.67，Alpha 和 Theta 频段的特异性约为 0.60 和 0.62。尽管如此，High Gamma 频段在整体训练损失最低、准确率最高，其敏感性和 F1 分数也优于其他频段，AUC 曲线下面积更是处于领先位置。这表明 High Gamma 频段所携带的高频神经振荡信息对 MDD 与健康状态的区分最具判别力，兼顾了模型的稳定收敛速度与高效的正负样本识别，因而在综合评价中依然确认其为本研究中最优的分类频段。

第四章 MDD 群体的亚型分析

在确认 High Gamma 频段最具诊断价值后，本章聚焦于该频段下 MDD 群体内部的异质性分析，旨在揭示潜在的亚型结构与脑区特征差异。首先通过对每位 MDD 受试者 High Gamma 信号的时序绝对振幅均值提取通道维度特征，并结合手肘法与轮廓系数法协同确定最佳聚类数；接着运用 K-Means 算法对特征矩阵进行划分，并通过 PCA 降维对聚类分布进行可视化。最后，本章选取各簇中心样本作为代表，绘制脑区振幅热力图与通道间 Pearson 相关的功能连接矩阵，从空间与网络层面全面比较 MDD 亚型间的神经活动模式，为抑郁症的精准分型与个性化干预提供了新视角。

4.1 实验设计

聚类前，需要对数据集进行特征提取，即从每个受试者的 epochs 数据中，针对所有通道计算其在各 epoch 上的时域绝对振幅均值，形成通道维度的特征向量。通过将所有受试者的通道均值特征进行堆叠，构建样本-特征矩阵。提取完特征后，实验使用经典的 K-Means 算法进行聚类。其中，实验综合手肘法与轮廓系数法的结果确定最终簇数，并对样本进行聚类标签赋值，从而确认 MDD 患者的各个亚型。

可视化方面，实验利用主成分分析（PCA）将高维特征降至二维，绘制聚类散点图，直观展示各簇在低维空间的分布。此外，对每个簇，计算簇中心并选取与其距离最近的代表性受试者，提取其原始 epochs 数据，用于后续脑区热力图绘制。然后，对于每个代表性样本，计算各通道的时序绝对振幅均值，构建通道-聚类矩阵并绘制热力图，从空间维度揭示不同簇间的振幅差异。最后，对两个亚型进行功能连接性分析：先选择代表性个体（基于各簇所选中心样本），加载其原始 epochs 数据，然后将所有 epoch 沿时间拼接形成通道×时间序列，计算通道间 Pearson 相关系数，生成功能连接性矩阵。

4.2 实验流程

Step 1：筛选 MDD 受试者

读取临床信息表格，严格保留 formal_status 字段值恰好为“MDD”的记录，排除带有其他共病标签的样本。

Step 2：匹配预处理数据

检查预处理数据存储目录，列出所有受试者文件夹名称；将临床表中受试者 ID 与目录名称进行匹配，筛除缺失预处理文件的个体。

Step 3：特征提取

对于每一位通过匹配的 MDD 受试者：

1. 定位其第一个被试 session 的 epochs 文件路径；

2. 使用 MNE 库加载 epochs 数据，获取形状为（epoch 数×通道数×时间点数）的三维数据阵；

3. 沿 epoch 和时间维度对数据取平均，获得长度等于通道数的特征向量；

4. 将该特征向量加入样本列表，同时记录受试者 ID。

5. 将所有受试者的特征向量堆叠为大小为（样本数×通道数）的矩阵 X。

Step 4：手肘法与轮廓系数分析

遍历不同簇数 k（手肘法 k=1…10，轮廓系数 k=2…10），分别计算并绘制：簇内失真随 k 的变化曲线和平均轮廓系数随 k 的变化曲线。综合两种指标，确定最佳簇数 best_k。

Step 5：最终聚类与降维可视化

以 best_k 为簇数，使用 KMeans 对矩阵 X 进行聚类，获得每个样本的簇标签；然后，对 X 进行 PCA 降维至二维，绘制基于簇标签着色的散点图。

Step 6：代表样本选取与脑区热力图绘制

对每个聚类：首先，计算该簇中所有样本特征向量的均值向量（簇中心）；接着，找到距离簇中心最近的样本索引，获取其受试者 ID；最后，再次加载该代表样本的原始 epochs 数据，计算各通道时序绝对振幅均值（转换为 μV）。得到上述结果后，将所有簇的通道均值数据合并为表格，以行对应簇、列对应通道并基于该表格绘制热力图，从空间分布角度比较各簇间振幅差异。

Step 7：功能连接性分析

对每个簇代表样本：拼接其所有 epoch 的通道时序，计算通道间 Pearson 相关系数矩阵；然后，将结果以热力图形式可视化，比较各簇代表样本的功能连接性模式。

4.3 实验结果

实验读取所有 MDD 患者的 EEG 信号的 High Gamma 频段时序信息，进行特征提取后使用手肘法和轮廓系数法来确定最佳簇数，实验结果如图 4-1，图 4-2 所示。

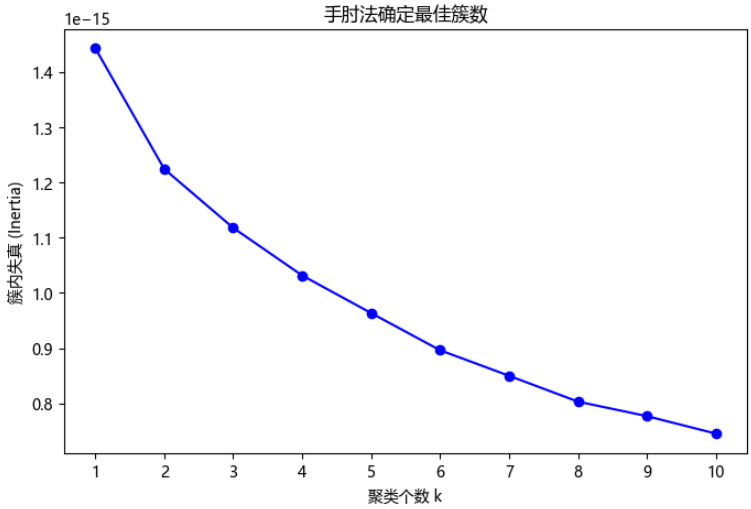

图 4-1 手肘法

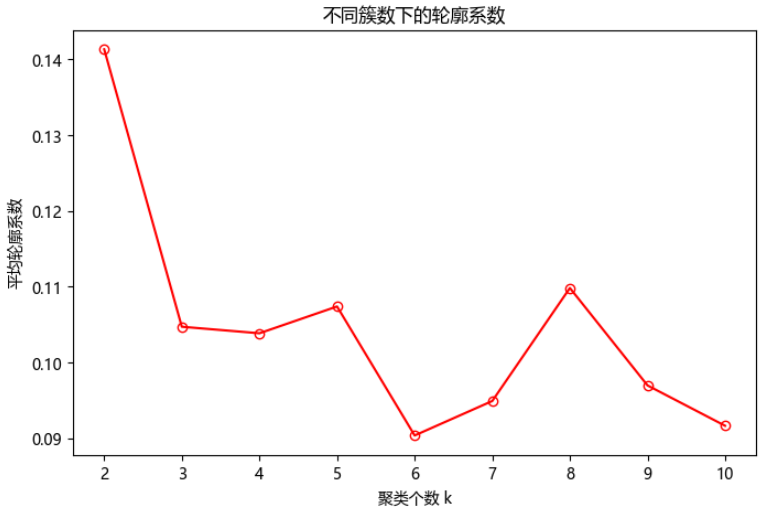

图 4-2 轮廓系数法

由图 4-1 可以看出，随着聚类数 k 从 1 增加到 2，簇内失真呈现出显著的下降趋势；而当 k 大于 2 时，失真下降的幅度明显减缓，表明在 k＝2 处出现了“拐点”，即手肘法所指示的最佳簇数。另一方面，参考图 4-2 的轮廓系数曲线，当 k ＝ 2 时所对应的平均轮廓系数达到了全局最大值，说明此时各簇内部的相似度最高且簇与簇之间的分离度最佳。从轮廓系数法的理论出发，最大轮廓系数对应的 k 值即为最优聚类数。综上所述，

无论是基于失真下降速率的手肘法，还是基于簇间分离度与簇内紧凑度的轮廓系数法，两种评估指标均一致地指向 k＝2。根据这一结论，在本实验中对所有样本采用 K-means 算法时，聚类数直接设置为 2，从而获得稳定且具有良好可分性的聚类结果，并进一步在此基础上进行后续可视化和分析，聚类结果图 4-3 所示。

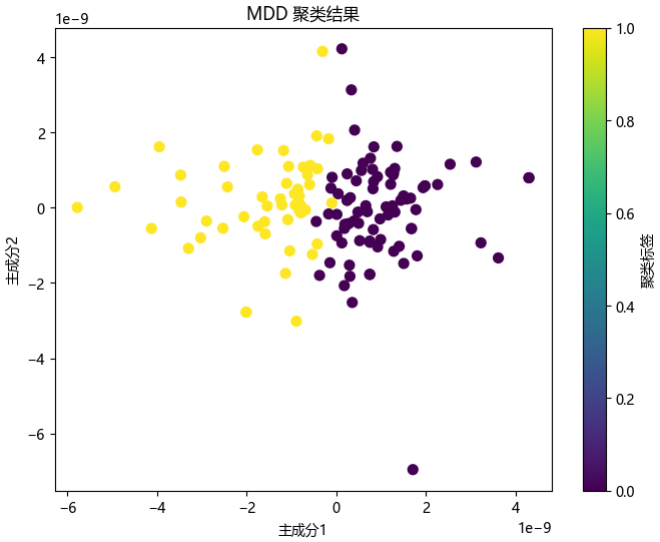

图 4-3 聚类结果

从图 4-3 中可以看到，两个簇在二维主成分空间中呈现出较为清晰且相对独立的分布：大多数样本点紧密分布于各自簇的中心区，簇内间距较小，表明同一簇内的样本具有较高的相似性和一致性。仅有少数样本点位于簇边缘或略微偏离其核心区域，但这种个别分散并未影响总体聚类结构的稳健性和可辨识性。总体而言，除了这些少数边缘点以外，绝大多数样本都被正确地分配到其所属簇内，聚类效果良好，簇间界限清晰且内部紧凑，为后续的代表样本选取和进一步分析提供了可靠基础。

得到两个聚类结果后，实验对两个聚类的中心进行计算，得到均值向量。然后，对所用数据集进行索引，找到中心位置对应的样本（视其为该簇的代表样本）。接着，再次读取该受试者 High Gamma 频段的原始时序数据，对每个通道沿时间维度计算其绝对振幅的平均值，以反映各个脑区在该亚型中的典型振幅水平。最后，将两位代表样本的通道振幅数据整合到一个通道×亚型矩阵中，绘制两个 MDD 亚型的脑区热力图，结果如图 4-4 所示，脑区通道分布图如图 4-5 所示[39]。

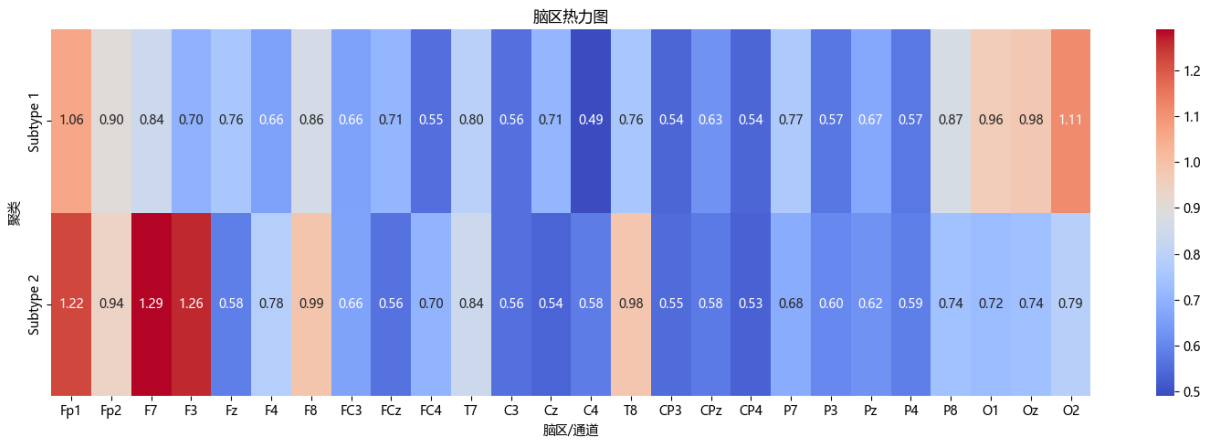

图 4-4 MDD 亚型脑区热力图

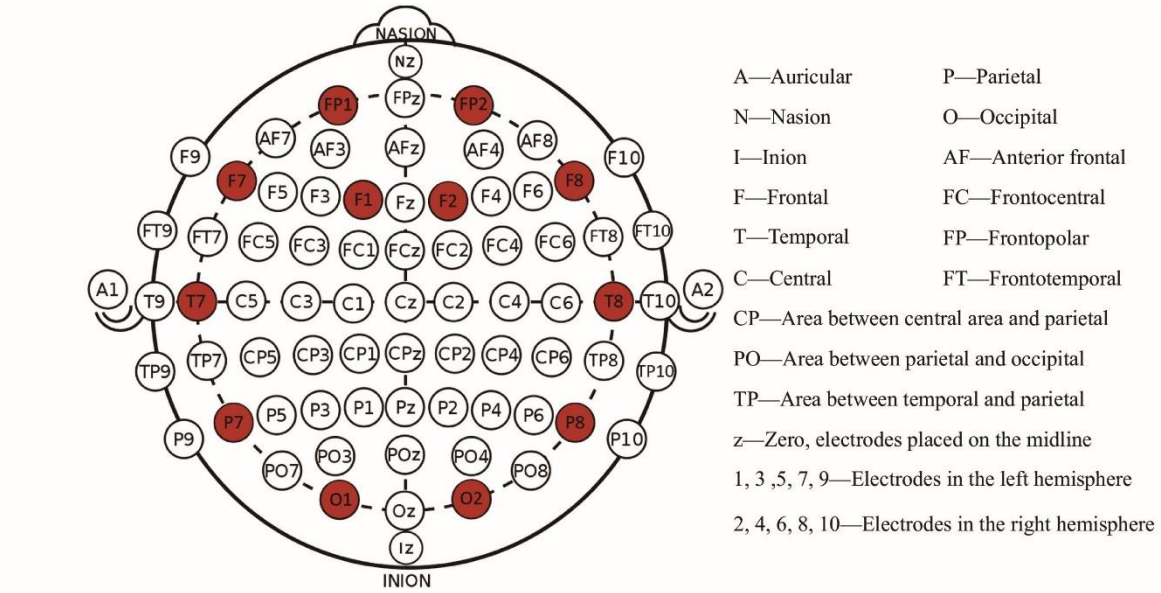

图 4-5 脑区通道分布图

图 4-4 显示，MDD 的两个亚型在各 EEG 通道的平均绝对振幅上存在显著差异。其中左侧额叶通道 F3、F7 与右侧颞叶通道 T8 的振幅在亚型间差异尤为显著：Subtype 2 的 F3、F7、T8 振幅显著高于 Subtype 1，而 Subtype 1 在枕叶区（O1、Oz、O2）振幅普遍高于 Subtype 2。F3、F7 对应的左侧背外侧和腹侧前额叶皮层参与执行功能和情绪调节，已有研究表明抑郁患者常在这些区域表现出活动水平下降的模式，例如 F3、F7 的 Alpha 波不对称性与负性情绪和行为抑制密切相关[40]。因此 Subtype 2 的左额叶通道振幅增高可能反映其额叶网络活动的异质性或代偿性激活。右侧颞叶区域 T8 包含杏仁核等与情绪记忆和加工相关的结构，对情绪体验的感知与记忆起关键作用[41]，其振幅增高提示该亚型在情绪信息加工上可能具有不同特征。相对而言，Subtype 1 枕叶区振幅较大，表明该亚型视觉皮层及后部注意网络活动更为活跃。文献指出 MDD 患者常伴有注

意力和认知控制功能受损[42]，而枕叶区神经振荡的改变与注意力分配及视觉处理能力下降相关[43]。综合而言，不同 MDD 亚型间的前额叶-颞叶网络与枕叶-注意网络振幅模式存在明显区别，这可能反映了两种亚型在情绪调节和认知控制机制上的差异[40]。

两个 MDD 亚型的功能连接性矩阵分别如图 4-6，图 4-7 所示。注意，这里为了便于连接性分析，将样本的所有 epoch 拼接后计算 Pearson 系数；因为在单 epoch 的 High Gamma 频段的 Pearson 系数过小难以分析，拼接后将信号中的包络不断累积，扩大了 Pearson 系数（可以看作是一种在相同数量级上的对比，只是扩充了倍数）。

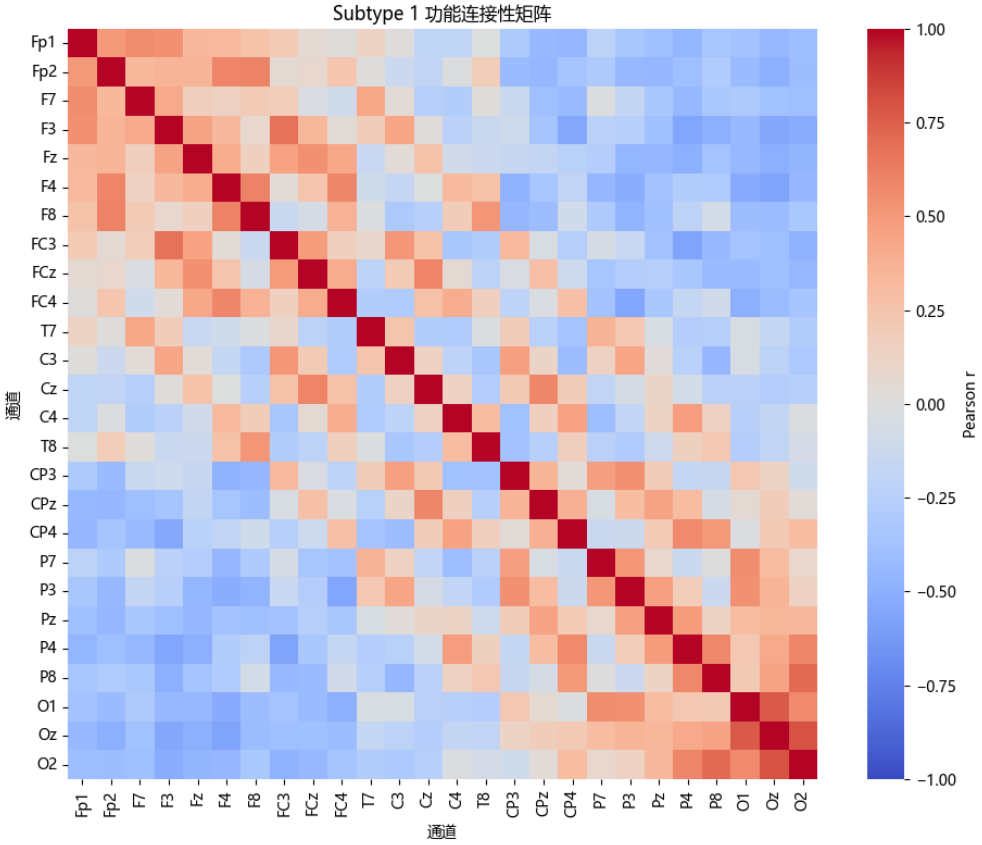

图 4-6 Subtype 1 的功能连接性矩阵

Subtype 1 的功能连接性矩阵显示，前额叶通道（F3、F7、Fz）之间仅呈现较弱程度的正相关（浅红色甚至偏白），而枕叶通道（O1、Oz、O2）之间的相关性尤为显著（更趋于深红）。Subtype 1 中 O1、Oz、O2 之间的 Pearson 相关系数接近 1.0，远高于前额叶节点的水平。右侧颞叶通道（T8、F8）在 Subtype 1 中也表现出中等程度的正相关（约 0.6 左右）。总体而言，Subtype 1 呈现出以后部脑区（尤其是枕叶）为主的高同步性，而前额叶连接性相对较弱。

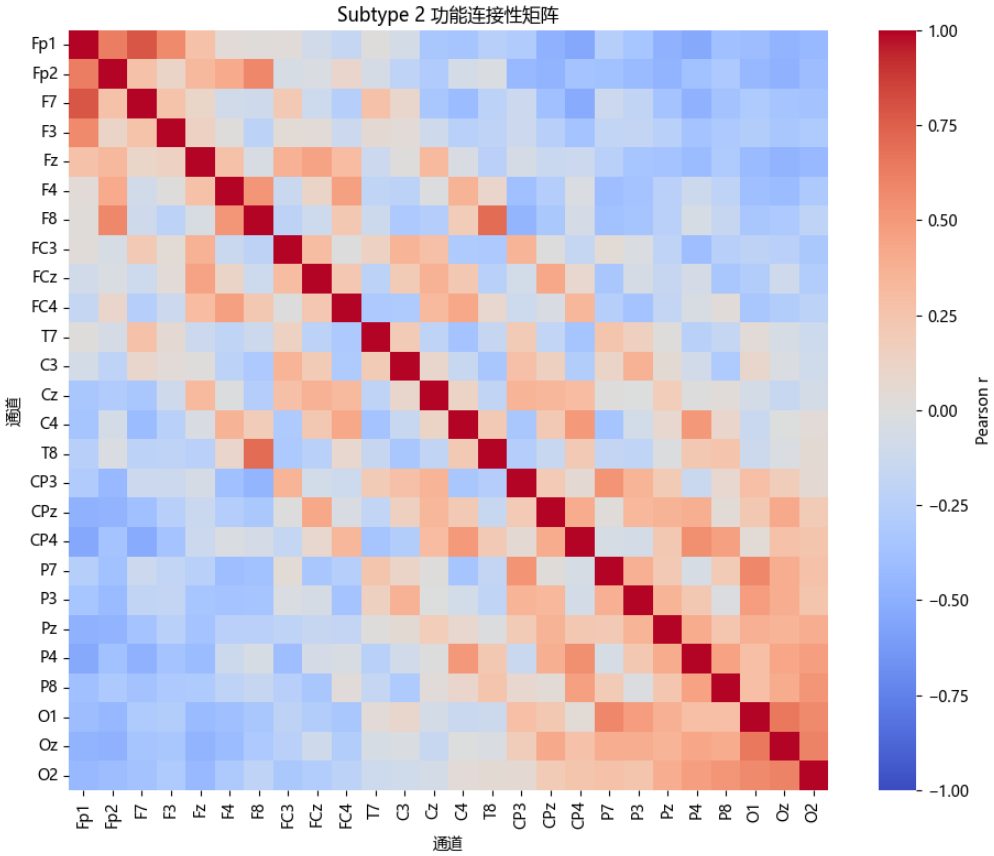

图 4-7 Subtype 2 的功能连接性矩阵

相较而言，Subtype 2 的矩阵在左侧前额叶区域（Fp1、F7）以及右侧颞极（T8、F8）处出现极高的相关性（深红色），表明这些通道对间 Pearson r 值接近 1.0；而枕叶通道（O1、Oz、O2）相较 Subtype 1 的相关性稍弱，这与热力图的结果是一致的。换言之，Subtype 2 的功能连接模式更偏向于前额-颞叶网络，而后部视觉区的同步性明显低于 Subtype 1。前额叶（尤其左前额叶）节点与颞叶的强连接提示 Subtype 2 可能具有更强的执行控制或注意力网络参与度。

前额叶皮层在情绪和注意力调节中起关键作用。Koolschijn 等通过在 MDD 患者与对照组间比较不同频段的功能连接性，指出在 Theta 频段中，前额叶与颞叶节点的同步度与抑郁严重度呈正相关，表明这一回路在 MDD 情绪调节与记忆加工中扮演关键角色[44]，与 Subtype 2 的高前额-颞叶连接性高度一致。而 Subtype 1 中前额叶连接性不足则可能与注意控制减弱相关。此外，Leuchter 等人在首发且未用药 MDD 患者中发现，与健康对照组相比，Gamma 频段在枕叶区域表现出显著提升（包括 O1–Oz–O2 通道对）的相干性[45]，这证明了 Subtype 1 枕叶区高连接性的合理性。另一方面，枕叶区域（O1、Oz、O2）多属于视觉和默认网络核心，Subtype1 中这些区域高度互联，说明该亚型脑区

可能对应更多的视觉加工或空间注意相关活动。简而言之，Subtype 1 偏向“后部—视觉/空间”网络的高度同步，Subtype 2 偏向“前额—颞叶”网络的显著耦合，两者在脑区网络分布与功能侧重点上存在明显差异。

综合脑区热力图和功能连接性矩阵可知，Subtype 1 和 Subtype 2 的主要区别在于前者的枕叶-注意网络连接性强，可能反映该亚型在空间注意和视觉加工过程中具有更强的网络整合与信息传递能力。而后者的前额叶-颞叶网络同步率更高，提示这一亚型在情绪调节或执行控制回路中的功能耦合更为活跃。简单来说，两个不同亚型的强功能连接性区域不同，Subtype 1 主要分布在脑区后部，Subtype 2 主要分布在脑区前部。此发现不仅深化了我们对 MDD 内部异质性的理解，也为基于 EEG 功能连接性指标的个性化诊断策略提供了有力依据，有助于未来针对不同 MDD 亚型制定更精准的干预和治疗方案。

总结与展望

1. 论文工作总结

本文介绍了 EEG 信号对 MDD 诊断的研究背景和基础知识，阐明了研究动机，并且介绍了实验设计思路和实验流程，对所得结果进行了详细分析。本文的主要贡献是在多频段内发现 High Gamma 频段对于诊断 MDD 有着最强的判别性以及在亚型分析研究时发现两个不同亚型的强功能连接性区域不同，Subtype 1 主要分布在脑区后部，Subtype 2 主要分布在脑区前部。上述发现对于 MDD 未来的诊断和个性化治疗有着重大帮助。

MDD 诊断方面，本研究聚焦基于多频段 EEG 信号对 MDD 与健康对照 HC 个体的二分类，首先对原始时序数据进行欧几里得对齐与被试内归一化，保留各频段完整的时间—空间结构，并分别构建 Alpha、Beta、Delta、Theta、Low Gamma 与 High Gamma 六个子频段的训练集与验证集（训练集中正负样本数量平衡、验证集中正例远多于负例）。在此基础上，设计了包含时间卷积、空间卷积、平方映射与全局自适应平均池化的 M-ShallowConvNet 架构。训练结果显示，High Gamma 频段模型以最低的训练损失和最高的分类准确率领先于其他频段，其敏感性、F1 值与 AUC 同样位列首位，特异性略低于 Beta 和 Theta 频段。综合损失、准确率及各项评估指标，可知 High Gamma 频段所承载的高频振荡特征对于 MDD 与 HC 的区分具有最强判别力，而较低频段如 Alpha 与 Theta 则表现相对欠佳。该研究验证了多频段 EEG 特征在抑郁症检测中的潜力，并为后续基于频谱特征的精准诊断提供了重要参考。

MDD 亚型划分方面，通过对严格筛选出的 MDD 患者 High Gamma 频段 EEG 数据进行时域特征提取与无监督 K-means 聚类，并结合手肘法与轮廓系数两种评估方法最终确定簇数为 2，实验将所有受试者划分为两大亚型，并分别选取各簇的中心样本进行深入分析。首先从所有 epoch 数据中沿时间维度计算各通道绝对振幅均值，构建特征矩阵并在二维主成分空间中可视化聚类结果；接着对两个簇计算簇心最接近的代表样本，再基于其原始时序数据生成脑区振幅热力图，发现 Subtype 1 在枕叶通道（O1、Oz、O2）的振幅显著高于 Subtype 2，而 Subtype 2 则在左前额叶通道（F3、F7）与右侧颞叶通道（T8）表现出更强的振幅水平；最后对这两个代表样本分别计算功能连接性矩阵，进一步揭示 Subtype 1 后部视觉与空间注意网络的高耦合特征与 Subtype 2 前额-颞叶情绪/记

忆回路的紧密协同差异。

2. 工作展望

虽然本研究在基于 EEG 信号对多频段的 MDD 诊断和 MDD 亚型划分有一定成果，但是由于 TDBRAIN 数据集上线时间相对较短，基于该数据集的工作较少，研究 MDD 的工作更少，能够印证的相关工作不多。因此，本研究仍有很大的提升空间，详情如下：

首先，扩充数据集。TDBRAIN 数据集的 MDD 人群与 HC 人群偏少，占数据集的一小部分，得到的结果只是该数据集内成立。今后可以考虑使用更大、更多源的数据集进行实验研究，这样得到的结果更准确，也更具普适性。

其次，研究 MDD 人群 EEG 信号的其他频段。本次工作中，High Gamma 频段的诊断效果最好。但是以往有相关研究指出 Alpha、Theta 等低频段也能提供抑郁状态的信息[38]，但在本次分类任务中，这些低频信号的判别能力并不显著，或许需要结合其他特征或更复杂的模型架构才能发挥作用。此外，对于 MDD 亚型划分的工作也只对 High Gamma 频段的 EEG 信号进行了处理。今后可以对其他分类不错的频段，如 Low Gamma 和 Beta 等频段进行 MDD 亚型划分，也许会有更好的划分结果。

参考文献

[1] Chen D, Wang X, Voon V, et al. Neurophysiological stratification of major depressive disorder by distinct trajectories[J]. Nature Mental Health, 2023, 1(11): 863-875.

[2] Zhang Y, Wu W, Toll R T, et al. Identification of psychiatric disorder subtypes from functional connectivity patterns in resting-state electroencephalography[J]. Nature Biomedical Engineering, 2021, 5(4): 309-323.

[3] Voetterl H T S, Sack A T, Olbrich S, et al. Alpha peak frequency-based Brainmarker-I as a method to stratify to pharmacotherapy and brain stimulation treatments in depression[J]. Nature Mental Health, 2023, 1(12): 1023-1032.

[4] Michel C M, Brunet D. EEG source imaging: a practical review of the analysis steps[J]. Frontiers in Neurology, 2019, 10: 325.

[5] Yasin S, Hussain S A, Aslan S, et al. EEG based Major Depressive disorder and Bipolar disorder detection using Neural Networks: A review[J]. Computer Methods and Programs in Biomedicine, 2021, 202: 106007.

[6] Khodayari A, Reilly J P, Hasey G M, et al. A machine learning approach using EEG data to predict response to SSRI treatment for major depressive disorder[J]. Clinical Neurophysiology, 2013, 124(10): 1975-1985.

[7] Chen H, Lei Y, Li R, et al. Resting-state EEG dynamic functional connectivity distinguishes non-psychotic major depression, psychotic major depression and schizophrenia[J]. Molecular Psychiatry, 2024, 29(4): 1088-1098.

[8] Mumtaz W, Ali S S A, Yasin M A M, et al. A machine learning framework involving EEG-based functional connectivity to diagnose major depressive disorder (MDD)[J]. Medical & Biological Engineering & Computing, 2018, 56: 233-246.

[9] Duan L, Duan H, Qiao Y, et al. Machine learning approaches for MDD detection and emotion decoding using EEG signals[J]. Frontiers in Human Neuroscience, 2020, 14: 284.

[10] 李建秀. 基于脑电图的重度抑郁症脑连接异常模式及算法研究[D]. 兰州大学, 2022.

[11] He B, Ding L, Sohrabpour A. Electrophysiological mapping and source imaging[J]. Neural engineering, 2020: 379-413.

[12] Van N, Vollebregt M A, Van M J A M, et al. Frontal alpha asymmetry as a diagnostic marker in depression: Fact or fiction? A meta-analysis[J]. Neuroimage: clinical, 2017, 16: 79-87.

[13] Spironelli C, Fusina F, Angrilli A. Delta and theta eeg activity during resting state is altered in patients affected by major depression[J]. European Psychiatry, 2021, 64(S1): S338-S339.

[14] Pizzagalli D A, Webb C A, Dillon D G, et al. Pretreatment rostral anterior cingulate cortex theta activity in relation to symptom improvement in depression: a randomized clinical trial[J]. JAMA Psychiatry, 2018, 75(6): 547-554.

[15] Li P, Yokoyama M, Okamoto D, et al. Resting-state EEG features modulated by depressive state in healthy individuals: insights from theta PSD, theta-beta ratio, frontal-parietal PLV, and sloreta[J]. Frontiers in Human Neuroscience, 2024, 18: 1384330.

[16] Sun S, Li J, Chen H, et al. A study of resting-state EEG biomarkers for depression recognition[J]. Arxiv Preprint Arxiv, 2020, 2002: 11039,.

[17] Akbari H, Sadiq M T, Rehman A U, et al. Depression recognition based on the reconstruction of phase space of EEG signals and geometrical features[J]. Applied Acoustics, 2021, 179: 108078.

[18] Lemaitre C, Charles A, Sarma S V. Exploration of a Network-Based EEG Marker for Major Depressive Disorder[C]. 2024 46th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC). IEEE, 2024: 1-4.

[19] Dau E G. Evaluating the impact of preprocessing pipelines on EEG-based machine learning models for MDD classification[D]. Tilburg University, 2024.

[20] Simmatis L, Russo E E, Geraci J, et al. Technical and clinical considerations for electroencephalography-based biomarkers for major depressive disorder[J]. Npj Mental Health Research, 2023, 2(1): 18.

[21] Liu S, An L, Jia Z. A Domain Adversarial Learning Framework for Major Depression Disorder Diagnosis[C]. ICASSP 2025-2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2025: 1-5.

[22] Umair M, Ahmad J, Alasbali N, et al. Decentralized EEG-based detection of major depressive disorder via transformer architectures and split learning[J]. Frontiers in Computational

Neuroscience, 2025, 19: 1569828.

[23] Zhang J, Li K, Yang B, et al. Local and global convolutional transformer-based motor imagery EEG classification[J]. Frontiers in Neuroscience, 2023, 17: 1219988.

[24] Siddhad G, Gupta A, Dogra D P, et al. Efficacy of transformer networks for classification of EEG data[J]. Biomedical Signal Processing and Control, 2024, 87: 105488.

[25] Wan Z, Li M, Liu S, et al. EEGformer: A transformer–based brain activity classification method using EEG signal[J]. Frontiers in Neuroscience, 2023, 17: 1148855.

[26] Liu R, Chao Y, Ma X, et al. ERTNet: an interpretable transformer-based framework for EEG emotion recognition[J]. Frontiers in Neuroscience, 2024, 18: 1320645.

[27] 张学工.模式识别:模式识别与机器学习第 4 版[M].北京:清华大学出版社，2021: 250.

[28] Van Dijk H, Van Wingen G, Denys D, et al. The two decades brainclinics research archive for insights in neurophysiology (TDBRAIN) database[J]. Scientific Data, 2022, 9(1): 333.

[29] Bomatter P, Paillard J, Garces P, et al. Machine learning of brain-specific biomarkers from EEG[J]. EBioMedicine, 2024, 106.

[30] Schirrmeister R T, Springenberg J T, Fiederer L D J, et al. Deep learning with convolutional neural networks for EEG decoding and visualization[J]. Human Brain Mapping, 2017, 38(11): 5391-5420.

[31] Kim S J, Lee D H, Lee S W. Rethinking CNN architecture for enhancing decoding performance of motor imagery-based EEG signals[J]. IEEE Access, 2022, 10: 96984-96996.

[32] Lin T Y, Goyal P, Girshick R, et al. Focal loss for dense object detection[C]. Proceedings of the IEEE International Conference on Computer Vision. 2017: 2980-2988.

[33] Ma J, Yang B, Qiu W, et al. A large EEG dataset for studying cross-session variability in motor imagery brain-computer interface[J]. Scientific Data, 2022, 9(1): 531.

[34] Yang B, Rong F, Xie Y, et al. A multi-day and high-quality EEG dataset for motor imagery brain-computer interface[J]. Scientific Data, 2025, 12(1): 488.

[35] Liao Y, Zhang Y, Wang S, et al. CLDTA: Contrastive Learning based on Diagonal Transformer Autoencoder for Cross-Dataset EEG Emotion Recognition[J]. Arxiv Preprint Arxiv, 2024, 2406: 08081.

[36] Luo T, Zhang J, Qiu Y, et al. M3D: manifold-based domain adaptation with dynamic distribution for non-deep transfer learning in cross-subject and cross-session eeg-based emotion recognition[J]. Arxiv Preprint Arxiv, 2024, 2404: 15615.

[37] Bethge D, Hallgarten P, Özdenizci O, et al. Exploiting multiple eeg data domains with adversarial learning[C]. 2022 44th Annual International Conference of the IEEE Engineering in Medicine & Biology Society (EMBC). IEEE, 2022: 3154-3158.

[38] Fitzgerald P J, Watson B O. Gamma oscillations as a biomarker for major depression: an emerging topic[J]. Translational psychiatry, 2018, 8(1): 177.

[39] Wang X, Li S, Li R, et al. Advances in the application of a brain–computer interface to the Metaverse[J]. Chinese Journal of Engineering, 2023, 45(9): 1528-1538.

[40] Gollan J K, Hoxha D, Chihade D, et al. Frontal alpha EEG asymmetry before and after behavioral activation treatment for depression[J]. Biological Psychology, 2014, 99: 198-208.

[41] Dolcos F, LaBar K S, Cabeza R. Interaction between the amygdala and the medial temporal lobe memory system predicts better memory for emotional events[J]. Neuron, 2004, 42(5): 855-863.

[42] 中华医学会精神医学分会抑郁障碍研究协作组. 抑郁症认知症状评估与干预专家共识[J].中华精神科杂志, 2020, 53(5):369-376.

[43] Xie X , Sha S, Cai H, et al. Resting-State Alpha Activity in the Frontal and Occipital Lobes and Assessment of Cognitive Impairment in Depression Patients[J]. Psychology Research and Behavior Management, 2024: 2995-3003.

[44] Movahed R A, Jahromi G P, Shahyad S, et al. A major depressive disorder classification framework based on EEG signals using statistical, spectral, wavelet, functional connectivity, and nonlinear analysis[J]. Journal of Neuroscience Methods, 2021, 358: 109209.

[45] Huang Y, Yi Y, Chen Q, et al. Analysis of EEG features and study of automatic classification in first-episode and drug-naïve patients with major depressive disorder[J]. BMC psychiatry, 2023, 23(1): 832.

致谢

在本论文的完成之际，我深感岁月静好，收获良多。

首先，衷心感谢我的导师顾正晖教授，从选题到实验设计再到论文撰写，顾教授始终给予耐心指导与悉心鼓励，每两周的汇报中我也能在交流中学习到许多。

感谢侍江烽学长在实验过程中的无私帮助与宝贵建议，无论是数据处理还是代码调试，他都倾囊相授，为本研究的顺利开展提供了重要支持。

同时，感谢我的家人，始终理解并包容我在科研路上的付出与坚持，是你们默默的关爱和鼓励让我能够无后顾之忧地投入学习与研究。

感谢我的同学和朋友，在实验设计、数据分析以及生活点滴中给予我的帮助与陪伴，让我在漫长的科研旅程中感受到温暖和力量。

最后，感谢所有关心、支持和帮助过我的人，正是因为有了你们的支持，我才能顺利完成这篇论文，并不断成长与进步。